Penurunan Model Markowitz ke Ising Hamiltonian

Daftar Isi

1 Pendahuluan: Risk-Return Trade-off **2**

2 Detail Komponen Matematis **2**
2.1 Suku Pertama: Risiko ($x^T \Sigma x$) 2
2.2 Suku Kedua: Return ($\lambda \mu^T x$) 3
2.3 Suku Ketiga: Penalti Batasan ($A(\sum x_i - K)^2$) 3

3 Transformasi Markowitz ke QUBO (General Form) **4**
3.1 Ekspansi Suku-Suku Objektif 4
3.2 Penggabungan dan Penyederhanaan 4
3.3 Definisi Matriks QUBO (Q) 4
3.4 Interpretasi Koefisien: 5

4 Transformasi QUBO ke Ising (General Form) **5**
4.1 Substitusi ke Bentuk QUBO 5
4.2 Identifikasi Parameter Hamiltonian 5
4.3 Representasi Operator Pauli 5

5 Ekspektasi Energi dan Optimasi Parametrik **5**
5.1 Ansatz Tanpa Entanglement 6
5.2 Gradien Analitik 6

6 Fondasi Teoritis: Prinsip Variasi **6**
6.1 Postulat Ground State 6
6.2 Generalisasi Hamiltonian untuk N Aset 6

7 Algoritma Variational Quantum Eigensolver (VQE) **7**
7.1 Alur Kerja Hybrid secara Matematis 7
7.2 Optimasi Parameter: SPSA vs. Gradient Descent 7
7.2.1 Masalah Gradient Descent (GD) 7
7.2.2 Mekanisme SPSA (Simultaneous Perturbation Stochastic Approximation) 8
7.2.3 Keunggulan SPSA untuk Markowitz-VQE 8

8 Arsitektur Ansatz: EfficientSU2 **8**
8.1 Formulasi Unitari Ansatz 8
8.2 Efek Entanglement pada Ekspektasi (Derivasi 2-Qubit) 9
8.3 Konvergensi Menuju Ground State 9

9 Implementasi dan Penentuan Solusi Portfolio **10**
9.1 Estimasi Probabilitas ((lihat Appendix H)) 10
9.2 Decoding ke Keputusan Investasi 10
9.3 Verifikasi Constraint (Post-Selection) 10

Appendix A Markowitz: Model Portofolio Modern **11**
A.1 Fondasi Filosofis dan Aksioma Dasar 11
A.1.1 Aksioma Rasionalitas (Risk Aversion) 11
A.1.2 Konvensi Risiko sebagai Volatilitas 11
A.1.3 Filosofi Diversifikasi 11
A.2 Postulat Matematis: Mean-Variance Optimization 11
A.2.1 Konstruksi Matriks Kovarians (Σ) 11
A.3 Transformasi ke Model Keputusan Biner ($x \in \{0, 1\}$) 12
A.4 Penanganan Batasan (The Penalty Term) 13
A.4.1 Mengapa Kuadratik? 13
A.5 Formulasi Akhir (The Markowitz Lagrangian) 13

Appendix B Risk Aversion Endogen: Pendekatan Sigmoid **14**
B.1 Urgensi: Mengapa Sigmoid? 14
B.2 Aksioma & Intuisi: Psikologi Keputusan 14
B.3 Reduksionisme: Kasus Minimal ($\mu = \sigma$) 14
B.3.1 Kondisi Seimbang 14
B.4 Jembatan Logika: Formalisme Fungsi Aktivasi 14
B.4.1 Persamaan Umum 15
B.5 Derivasi & Indeks Persamaan 15
B.5.1 Sensitivitas Selera terhadap Risiko 15
B.6 Verifikasi & Parameter: Batas Ekstrem 15
B.7 Physical Insight: Efek "Termostat" Kuantum 16
B.8 Kesimpulan 16

Appendix C Lagrange Multiplier dalam Markowitz-QUBO **17**
C.1 Definisi: Mengapa A disebut Bobot Penalti (Lagrange Multiplier)? 17
C.2 Hubungan dengan Metode Lagrange Standar 17
C.3 Penurunan Rumus Penalti 17
C.4 Fungsi Umum Lagrange Multiplier 18
C.5 Strategi Menentukan Nilai A 18
C.5.1 Pendekatan Teoretis (Upper Bound) 18
C.5.2 Rule of Thumb (Praktis) 18
C.5.3 Pencarian Grid (Grid Search / Hyperparameter Tuning) 18
C.5.4 Penalti Dinamis (Annealing Schedule) 19
C.5.5 Normalisasi Fungsi Objektif 19

Appendix D Teorema Rayleigh-Ritz: Fondasi Matematis Prinsip Variasi **20**
D.1 Filosofi: Kecenderungan Alam Meminimalkan Energi 20
D.2 Kalkulus Variasi: Mencari Titik Stasioner Energi 20
D.2.1 Definisi Fungsional Energi 20
D.2.2 Variasi Fungsional ($\delta E = 0$) 20
D.3 Jembatan Logika: Menuju Persamaan Nilai Eigen 21
D.4 Reduksionisme: Pembuktian $E(\psi) \geq E_0$ 21

D.4.1 Ekspansi dalam Basis Eigen 21
D.4.2 Substitusi ke Rayleigh Quotient 21
D.5 Verifikasi & Parameter: Batas Bawah 22
D.6 Physical Insight: "Nature's Compass" 22

Appendix E Dekomposisi Hamiltonian: Dari Matriks Global ke String Pauli 23
E.1 Urgensi Eksplorasi: Masalah "Raksasa" di Ruang Hilbert 23
E.2 Aksioma & Intuisi: Matriks Pauli sebagai "Atom" Informasi 23
E.3 Reduksionisme: Kasus Minimal (1-Qubit) 23
E.3.1 Mencari Koefisien (Proyeksi Trace) 23
E.4 Jembatan Formalisme & Logika: Banyak Qubit (Many-Body) 24
E.5 Derivasi "Scratchpad" & Indeks Persamaan: Linearitas Ekspektasi 24
E.6 Verifikasi & Parameter: Portofolio Markowitz-Ising 24
E.7 Analogi "Physical Insight": Spektroskopi Operator 25
E.8 Kesimpulan 25

Appendix F Parameter Shift Rule (PSR) 26
F.1 Sejarah Singkat 26
F.2 Definisi Matematis 26
F.3 Penurunan Rumus (Derivation) 26
F.3.1 Turunan Langsung 26
F.3.2 Ekspansi Pergeseran Parameter 27
F.3.3 Finalisasi 27
F.4 Keunggulan PSR 28

Appendix G Ekspansi State dalam Basis Eigen: Mekanisme Konvergensi Kuantum 29
G.1 Postulat Dasar: Spektrum Operator Hermitian 29
G.2 Jembatan 1: Prinsip Superposisi dan Resolusi Identitas 29
G.3 Jembatan 2: Normalisasi dan Konservasi Probabilitas 29
G.4 Jembatan 3: Nilai Ekspektasi dalam Representasi Spektral 30
G.5 Aplikasi pada VQE: Mekanisme Konvergensi 30
G.6 Kesimpulan 31

Appendix H Aturan Born: Jembatan Amplitudo ke Probabilitas 32
H.1 Postulat Dasar: State dalam Ruang Hilbert 32
H.2 Jembatan 1: Pengukuran sebagai Proyeksi 32
H.3 Postulat Born: Definisi Probabilitas 32
H.4 Jembatan 2: Nilai Ekspektasi dan Statistik Pengukuran 33
H.5 Jembatan 3: Implementasi pada Komputer Kuantum (Digital) 33
H.6 Ringkasan Aksioma Born 33

1 Pendahuluan: Risk-Return Trade-off

Dalam teori portofolio, kita mencari keseimbangan antara risiko dan keuntungan. Fungsi energi (objektif) dinyatakan sebagai:

$$E = \text{Risiko Total} - \text{Bobot Return} + \text{Penalti Batasan}$$

Tujuan utama adalah mencari **ground state** (kondisi energi minimum) yang berarti:

- Meminimalkan risiko ($\min x^T \Sigma x$)
- Memaksimalkan return ($\max \mu^T x \implies \min -\lambda \mu^T x$)
- Memenuhi batasan jumlah aset yang dibeli (Penalty term)

Secara matematis, model Markowitz (lihat Appendix A) untuk variabel biner $x_i \in \{0, 1\}$ adalah:

$$\min_{x \in \{0,1\}^N} \mathcal{L}(x) = x^T \Sigma x - \lambda \mu^T x + A \left(\sum_{i=1}^{N} x_i - K \right)^2$$

Dimana:

- N: Jumlah total aset tersedia.
- x_i: Keputusan investasi (1 jika dibeli, 0 jika tidak).
- μ: Vektor expected return.
- λ: Parameter *risk aversion* (toleransi risiko).
- Σ: Matriks kovarians (risiko antar aset).
- K: Jumlah aset yang ingin dipilih.
- A: Faktor penalti (Lagrange multiplier) untuk memastikan batasan terpenuhi.

---

2 Detail Komponen Matematis

2.1 Suku Pertama: Risiko ($x^T \Sigma x$)

$$x^T \Sigma x = \sum_{i=1}^{N} \sum_{j=1}^{N} \sigma_{ij} x_i x_j = \sum_{i} \sigma_i^2 x_i^2 + \sum_{i \neq j} \sigma_{ij} x_i x_j$$

Karena $x_i \in \{0, 1\}$, maka $x_i^2 = x_i$. Persamaan menjadi:

$$x^T \Sigma x = \sum_{i} \sigma_i^2 x_i + \sum_{i \neq j} \sigma_{ij} x_i x_j$$

Dimana σ_i^2 adalah varians aset i, dan σ_{ij} adalah kovarians antar aset. Kovarians dapat dihitung melalui perkalian deviasi standar kedua aset ($\sigma_i \sigma_j$) dengan koefisien korelasi (ρ_{ij}):

$$\sigma_{ij} = \sigma_i \sigma_j \rho_{ij}$$

Secara statistik, komponen-komponen ini dihitung sebagai berikut:

1. **Varians (σ_i^2):** mengukur volatilitas aset tunggal.

$$\sigma_i^2 = \frac{1}{T-1}\sum_{t=1}^{T}(R_{i,t} - \bar{R}_i)^2$$

2. **Kovarians (σ_{ij}):** mengukur hubungan pergerakan antar dua aset.

$$\sigma_{ij} = \frac{1}{T-1}\sum_{t=1}^{T}(R_{i,t} - \bar{R}_i)(R_{j,t} - \bar{R}_j)$$

3. **Korelasi (ρ_{ij}):** menormalisasi kovarians ke dalam rentang [-1, 1].

$$\rho_{ij} = \frac{\sigma_{ij}}{\sigma_i \sigma_j}$$

Dengan return harian $R_{i,t} = \frac{P_{i,t} - P_{i,t-1}}{P_{i,t-1}}$ dan $\bar{R}_i$ adalah rata-rata return.

2.2 Suku Kedua: Return ($\lambda \mu^T x$)

Menghitung keuntungan yang diharapkan:

$$\mu_A = \frac{1}{T}\sum_{t=1}^{T} R_{A,t}$$

suku pertama kedua Parameter λ dapat ditentukan secara endogen (misal melalui fungsi sigmoid):

$$\lambda = \frac{1}{1 + e^{-\mu/\sigma}}$$

Untuk penjelasan lebih detail, (lihat Appendix B)

2.3 Suku Ketiga: Penalti Batasan ($A(\sum x_i - K)^2$)

Karena QUBO adalah model optimasi *unconstrained* (tanpa kendala), batasan atau *constraint* harus dimasukkan ke dalam fungsi objektif sebagai penalti. Suku ini memastikan bahwa jumlah aset yang dipilih mendekati atau sama dengan K.

$$P(x) = A\left(\sum_{i=1}^{N} x_i - K\right)^2$$

Karakteristik suku penalti:

1. **Fungsi**: Jika $\sum x_i = K$, maka nilai penalti adalah 0 (minimum). Jika terjadi pelanggaran ($\sum x_i \neq K$), nilai energi akan meningkat secara kuadratik, sehingga algoritma akan menghindari solusi tersebut.
2. **Konstanta** A: Merupakan bobot penalti ((lihat Appendix C)). Nilai A harus dipilih cukup besar agar pelanggaran batasan "dihukum" lebih berat daripada potensi keuntungan dari risiko atau return, namun tidak terlalu besar sehingga merusak lanskap energi optimasi.

3. **Bentuk Ekspansi**:

$$A\left(\sum x_i - K\right)^2 = A\left(\sum_i x_i + 2\sum_{i<j} x_i x_j - 2K\sum_i x_i + K^2\right)$$

Ini menunjukkan bahwa batasan memberikan kontribusi baik pada suku linear maupun suku interaksi (kuadratik) dalam QUBO.

3 Transformasi Markowitz ke QUBO (General Form)

Untuk mentransformasikan model Markowitz ke dalam bentuk QUBO $\min \sum_{i,j} Q_{ij} x_i x_j$, kita harus mengekspansi seluruh suku dalam fungsi objektif $\mathcal{L}(x)$.

3.1 Ekspansi Suku-Suku Objektif

1. **Risiko:** $\sum_i \sigma_i^2 x_i + \sum_{i \neq j} \sigma_{ij} x_i x_j$
2. **Return:** $-\lambda \sum_i \mu_i x_i$
3. **Penalti:** $A\left(\sum_i x_i - K\right)^2 = A\left(\sum_i x_i^2 + 2\sum_{i<j} x_i x_j - 2K\sum_i x_i + K^2\right)$

3.2 Penggabungan dan Penyederhanaan

Substitusi properti biner $x_i^2 = x_i$:

$$\mathcal{L}(x) = \sum_i \sigma_i^2 x_i + \sum_{i \neq j} \sigma_{ij} x_i x_j - \lambda \sum_i \mu_i x_i + A\left(\sum_i x_i + 2\sum_{i<j} x_i x_j - 2K\sum_i x_i + K^2\right)$$

Kelompokkan berdasarkan derajat variabel (x_i dan $x_i x_j$):

$$\mathcal{L}(x) = \sum_i (\sigma_i^2 - \lambda\mu_i + A - 2AK) x_i + \sum_{i \neq j} (\sigma_{ij} + A) x_i x_j + AK^2$$

3.3 Definisi Matriks QUBO (Q)

Dalam format standar QUBO, koefisien dibagi menjadi diagonal (Q_{ii}) dan off-diagonal (Q_{ij}):

- **Elemen Diagonal (Suku Linear x_i):**

$$Q_{ii} = \sigma_i^2 - \lambda\mu_i + A(1 - 2K)$$

- **Elemen Off-Diagonal (Suku Interaksi $x_i x_j$):**

$$Q_{ij} = \sigma_{ij} + A$$

Sehingga fungsi objektif akhir dalam bentuk QUBO adalah:

$$\mathcal{L}(x) = \sum_{i=1}^{N} Q_{ii} x_i + \sum_{i<j}^{N} 2Q_{ij} x_i x_j + \text{offset}$$

di mana offset $= AK^2$. Dalam prakteknya, konstanta ini sering diabaikan karena tidak mempengaruhi lokasi titik minimum (*ground state*).

3.4 Interpretasi Koefisien:

1. Q_{ii}: Mengukur "daya tarik" aset i secara individu. Nilai akan mengecil (lebih disukai) jika return μ_i tinggi atau varians σ_i^2 rendah.
2. Q_{ij}: Mengukur hubungan antar dua aset. Nilai akan membesar (dihindari) jika kovarians σ_{ij} positif atau penalti A besar, yang memaksa sistem untuk memilih tepat K aset.

---

4 Transformasi QUBO ke Ising (General Form)

Untuk sistem N aset, kita menggunakan transformasi $x_i = \frac{1-s_i}{2}$ pada setiap variabel.

4.1 Substitusi ke Bentuk QUBO

$$E(s) = \sum_i Q_{ii} \left(\frac{1-s_i}{2}\right) + \sum_{i<j} 2Q_{ij} \left(\frac{1-s_i}{2}\right)\left(\frac{1-s_j}{2}\right) + \text{offset}$$

4.2 Identifikasi Parameter Hamiltonian

Setelah ekspansi aljabar, kita mendapatkan bentuk Ising $H = \sum_{i<j} J_{ij} s_i s_j + \sum_i h_i s_i + C$:

- **Interaksi (Coupling J_{ij}):**
$$J_{ij} = \frac{Q_{ij}}{2}$$
- **Medan Lokal (Field h_i):**
$$h_i = -\frac{1}{2}Q_{ii} - \sum_{j \neq i} \frac{Q_{ij}}{2}$$
- **Konstanta (Energy Offset C):**
$$C = \text{offset} + \sum_i \frac{Q_{ii}}{2} + \sum_{i<j} \frac{Q_{ij}}{2}$$

4.3 Representasi Operator Pauli

$$\hat{H} = \sum_{i<j} J_{ij} \hat{Z}_i \hat{Z}_j + \sum_i h_i \hat{Z}_i + C \cdot \hat{I}$$

Formula ini berlaku untuk jumlah aset N berapapun, menjadikannya model yang skalabel untuk optimasi portofolio besar.

---

5 Ekspektasi Energi dan Optimasi Parametrik

Tujuan kita adalah mencari parameter θ yang meminimalkan nilai ekspektasi Hamiltonian.

5.1 Ansatz Tanpa Entanglement

Jika kita menggunakan *ansatz* produk $|\psi(\theta)\rangle = \bigotimes_{i=1}^{N} R_y(\theta_i)|0\rangle$, nilai ekspektasi energinya adalah:

$$\langle E(\theta)\rangle = \sum_{i<j} J_{ij}\cos(2\theta_i)\cos(2\theta_j) + \sum_i h_i \cos(2\theta_i) + C$$

Fungsi ini adalah lanskap energi non-linear yang akan ditelusuri oleh *optimizer* klasik. Secara fisik, θ_i menentukan probabilitas "spin" aset i mengarah ke $+1$ atau -1.

5.2 Gradien Analitik

Gradien terhadap parameter θ_k dapat dihitung secara langsung:

$$\frac{\partial\langle E\rangle}{\partial\theta_k} = -2\sin(2\theta_k)\left[\sum_{j\neq k} J_{kj}\cos(2\theta_j) + h_k\right]$$

Persamaan gradien ini menunjukkan bahwa perubahan pada satu aset θ_k dipengaruhi oleh "medan efektif" yang dihasilkan oleh aset lainnya (J_{kj}) dan medan lokalnya sendiri (h_k).

---

6 Fondasi Teoritis: Prinsip Variasi

Penurunan pada Bab 5 adalah contoh spesifik untuk 2 aset. Secara umum, algoritma VQE (Variational Quantum Eigensolver) didasarkan pada salah satu postulat fundamental dalam mekanika kuantum, yaitu **Prinsip Variasi** (atau Teorema Rayleigh-Ritz (lihat Appendix D)).

6.1 Postulat Ground State

Setiap sistem kuantum didefinisikan oleh operator Hamiltonian $\hat{H}$. Energi dari state mana pun $|\psi\rangle$ dinyatakan sebagai nilai ekspektasi:

$$E(\psi) = \frac{\langle\psi|\hat{H}|\psi\rangle}{\langle\psi|\psi\rangle}$$

Prinsip variasi menyatakan bahwa untuk sembarang *trial state* (state percobaan) $|\psi\rangle$, nilai ekspektasi energinya tidak akan pernah lebih rendah dari energi *ground state* (E_0):

$$E(\psi) \geq E_0$$

6.2 Generalisasi Hamiltonian untuk N Aset

Berdasarkan transformasi Ising pada Bab 4, Hamiltonian untuk N aset dapat dituliskan secara umum sebagai:

$$\hat{H} = \sum_{i=1}^{N}\sum_{j>i}^{N} J_{ij}\hat{Z}_i\hat{Z}_j + \sum_{i=1}^{N} h_i\hat{Z}_i + \text{offset}\cdot\hat{I}$$

Untuk sebuah *trial state* $|\psi(\theta)\rangle$, nilai ekspektasi energi total adalah:

$$\langle E(\theta)\rangle = \sum_{i<j} J_{ij}\langle \hat{Z}_i \hat{Z}_j\rangle_\theta + \sum_i h_i \langle \hat{Z}_i\rangle_\theta + \text{offset}$$

Jika kita menggunakan *ansatz* rotasi independen seperti pada Bab 5, di mana $|\psi(\theta)\rangle = \bigotimes_{i=1}^N R_y(\theta_i)|0\rangle$, maka: 1. **Suku Linear:** $\langle \hat{Z}_i\rangle = \cos(2\theta_i)$ 2. **Suku Interaksi:** $\langle \hat{Z}_i \hat{Z}_j\rangle = \cos(2\theta_i)\cos(2\theta_j)$

Sehingga fungsi biaya (cost function) yang akan diminimalkan secara klasik adalah:

$$J(\theta) = \sum_{i<j} J_{ij}\cos(2\theta_i)\cos(2\theta_j) + \sum_i h_i \cos(2\theta_i) + \text{offset}$$

---

7 Algoritma Variational Quantum Eigensolver (VQE)

VQE adalah algoritma *hybrid quantum-classical* yang memetakan masalah minimisasi energi ke dalam loop optimasi parameter θ.

7.1 Alur Kerja Hybrid secara Matematis

1. **Preparasi State:** QPU menyiapkan state $|\psi(\theta)\rangle = U(\theta)|0\rangle^{\otimes n}$.
2. **Dekomposisi Hamiltonian** (lihat Appendix E): Hamiltonian $\hat{H}$ adalah kombinasi linear suku-suku Pauli $P_k \in \{I, X, Y, Z\}^{\otimes n}$:

$$\hat{H} = \sum_k c_k \hat{P}_k$$

3. **Pengukuran:** Nilai ekspektasi dihitung sebagai:

$$\langle \hat{H}\rangle_\theta = \sum_k c_k \langle \psi(\theta)|\hat{P}_k|\psi(\theta)\rangle$$

4. **Optimasi:** Optimizer klasik mencari θ^* yang meminimalkan $\langle \hat{H}\rangle_\theta$.

7.2 Optimasi Parameter: SPSA vs. Gradient Descent

Dalam sistem kuantum riil (noisy), estimasi gradien menggunakan *Parameter Shift Rule* (lihat Appendix F) atau beda hingga (*finite difference*) sangat rentan terhadap *noise* karena memerlukan banyak pengukuran ($2N$ pengukuran per iterasi).

7.2.1 Masalah Gradient Descent (GD)

GD menghitung turunan parsial terhadap setiap parameter θ_i secara bergantian. Pada lanskap energi yang "kasar" akibat *noise* statistik (*shot noise*), GD cenderung terjebak pada *local minima* atau gagal konvergen karena estimasi gradien yang bias.

7.2.2 Mekanisme SPSA (Simultaneous Perturbation Stochastic Approximation)

SPSA adalah algoritma optimasi stokastik yang jauh lebih efisien untuk VQE. Alih-alih mengukur gradien satu per satu, SPSA melakukan perturbasi pada **seluruh parameter sekaligus** menggunakan vektor acak Δ:

1. **Perturbasi Acak:** Pilih vektor Δ_k di mana setiap elemen bernilai ± 1 secara acak (distribusi Bernoulli).
2. **Estimasi Gradien Stokastik:** Hitung gradien pendekatan $g(\theta_k)$ hanya dengan **dua pengukuran** fungsi biaya:

$$\hat{g}(\theta_k) = \frac{E(\theta_k + c_k\Delta_k) - E(\theta_k - c_k\Delta_k)}{2c_k\Delta_k}$$

   di mana c_k adalah besarnya perturbasi yang mengecil seiring iterasi.
3. **Update Parameter:**

$$\theta_{k+1} = \theta_k - a_k\hat{g}(\theta_k)$$

7.2.3 Keunggulan SPSA untuk Markowitz-VQE

- **Efisiensi Skalabilitas:** Hanya memerlukan 2 *evaluasi fungsi* per iterasi, terlepas dari jumlah aset N. GD memerlukan $2N$ evaluasi.
- **Robustness terhadap Noise:** SPSA memiliki sifat "averaging" alami yang membuatnya lebih tahan terhadap fluktuasi statistik hasil pengukuran QPU dibandingkan *optimizer* berbasis gradien analitik.
- **Konvergensi Global:** Karena sifat stokastiknya, SPSA memiliki peluang lebih besar untuk melompati *local minima* kecil pada lanskap energi portfolio.

---

8 Arsitektur Ansatz: EfficientSU2

Untuk menangani korelasi aset yang kompleks (suku J_{ij}), kita memerlukan *ansatz* yang memiliki *entanglement*.

8.1 Formulasi Unitari Ansatz

Sirkuit `EfficientSU2` didefinisikan sebagai operator uniter $U(\theta)$ yang terdiri dari d lapisan (*layers*):

$$U(\theta) = L_d \dots L_1 L_0$$

Di mana setiap lapisan L_l (untuk $l > 0$) terdiri dari: 1. **Entanglement Layer (V_{ent}):** Biasanya berupa gerbang CNOT linear atau full.

$$V_{ent} = \prod_{(i,j)\in\text{pairs}} CX_{i,j}$$

2. **Rotation Layer ($R(\theta)$):**

$$R_i(\theta) = R_z(\theta_{i,l,2})R_y(\theta_{i,l,1})$$

8.2 Efek Entanglement pada Ekspektasi (Derivasi 2-Qubit)

Filosofi: Entanglement adalah sumber daya non-lokal yang memungkinkan *ansatz* mengeksplorasi korelasi yang tidak dapat dipisahkan (*non-separable*).

Jembatan Logika: Kita bandingkan nilai ekspektasi $\langle \hat{Z}_1 \hat{Z}_2 \rangle$ antara sistem tanpa *entanglement* (Bab 6) dan sistem dengan *entanglement* (1 *layer* CNOT).

1. **State Awal (Setelah Rotasi R_y):**

$$|\phi\rangle = R_y(2\theta_1)|0\rangle \otimes R_y(2\theta_2)|0\rangle$$

$$|\phi\rangle = (\cos\theta_1|0\rangle + \sin\theta_1|1\rangle) \otimes (\cos\theta_2|0\rangle + \sin\theta_2|1\rangle)$$

(Catatan: Menggunakan konvensi Bab 5 di mana rotasi menghasilkan $\cos\theta$*)*

2. **Aplikasi Entanglement (CNOT):**

$$|\psi\rangle = CX_{1,2}|\phi\rangle$$

$$|\psi\rangle = \cos\theta_1\cos\theta_2|00\rangle + \cos\theta_1\sin\theta_2|01\rangle + \sin\theta_1\cos\theta_2|11\rangle + \sin\theta_1\sin\theta_2|10\rangle$$

(Perhatikan bahwa koefisien $|10\rangle$ *dan* $|11\rangle$ *tertukar karena kontrol qubit 1 bernilai 1)*

3. **Pengukuran Ekspektasi $\langle \hat{Z}_1 \hat{Z}_2 \rangle$:**

$$\langle \hat{Z}_1 \hat{Z}_2 \rangle = \sum_{x \in \{0,1\}^2} P(x) \cdot \mathrm{val}(\hat{Z}_1 \hat{Z}_2)$$

$$\langle \hat{Z}_1 \hat{Z}_2 \rangle = (|\cos\theta_1\cos\theta_2|^2)\cdot(1) + (|\cos\theta_1\sin\theta_2|^2)\cdot(-1) + (|\sin\theta_1\cos\theta_2|^2)\cdot(1) + (|\sin\theta_1\sin\theta_2|^2)\cdot(-1)$$

$$\langle \hat{Z}_1 \hat{Z}_2 \rangle = \cos^2\theta_1(\cos^2\theta_2 - \sin^2\theta_2) + \sin^2\theta_1(\cos^2\theta_2 - \sin^2\theta_2)$$

$$\langle \hat{Z}_1 \hat{Z}_2 \rangle = (\cos^2\theta_1 + \sin^2\theta_1)\cos(2\theta_2) = \cos(2\theta_2)$$

Kesimpulan Jembatan: Dibandingkan dengan sistem tanpa *entanglement* ($\cos 2\theta_1 \cos 2\theta_2$), *entanglement* "mencampur" parameter sehingga korelasi antar *qubit* tidak lagi bersifat multiplikatif sederhana. Ini memberikan derajat kebebasan bagi VQE untuk merepresentasikan kovarians aset yang kompleks dalam model Markowitz.

8.3 Konvergensi Menuju Ground State

Filosofi: Optimasi adalah proses "pendinginan" numerik di mana state $|\psi(\theta)\rangle$ dipaksa sejajar dengan eigenvector energi terendah.

Jembatan Logika: Menggunakan Ekspansi State (lihat Appendix G) dalam basis eigen Hamiltonian $\hat{H}|v_i\rangle = E_i|v_i\rangle$.

1. **Ekspansi State Parametrik:**

$$|\psi(\theta)\rangle = \sum_{i=0}^{2^n-1} \alpha_i(\theta)|v_i\rangle$$

di mana $\sum |\alpha_i(\theta)|^2 = 1$.

2. **Ekspektasi Energi:**
$$E(\theta) = \sum_i E_i |\alpha_i(\theta)|^2$$

3. **Proses Minimisasi:** Selama iterasi optimasi klasik, parameter θ diperbarui sedemikian sehingga bobot probabilitas α_i untuk $i > 0$ (state eksitasi) menuju nol, dan bobot untuk $i = 0$ (*ground state*) menuju satu:
$$\lim_{\theta \to \theta^*} |\alpha_0(\theta)|^2 \approx 1$$
$$\lim_{\theta \to \theta^*} E(\theta) \approx E_0$$

Hasil akhirnya adalah state $|\psi(\theta^*)\rangle$ yang merupakan aproksimasi terbaik dari solusi portfolio optimal dalam ruang Hilbert.

---

9 Implementasi dan Penentuan Solusi Portfolio

Setelah konvergensi dicapai pada θ^*, kita melakukan ekstraksi solusi melalui pengukuran akhir.

9.1 Estimasi Probabilitas ((lihat Appendix H))

Probabilitas terpilihnya konfigurasi portfolio biner $x \in \{0,1\}^N$ diberikan oleh:
$$P(x) = |\langle x|\psi(\theta^*)\rangle|^2$$

Dalam eksekusi riil dengan M kali percobaan (*shots*), probabilitas ini diestimasi sebagai:
$$\hat{P}(x) = \frac{\text{jumlah kemunculan bitstring } x}{M}$$

9.2 Decoding ke Keputusan Investasi

Hasil akhir adalah *bitstring* x dengan probabilitas tertinggi:
$$x_{opt} = \arg\max_x \hat{P}(x)$$

- Jika $x_{opt} = [1, 0, 1, 0]$, maka keputusannya adalah membeli aset 1 dan 3, serta tidak membeli aset 2 dan 4.

9.3 Verifikasi Constraint (Post-Selection)

Karena suku penalti A dalam QUBO, solusi yang paling sering muncul diharapkan memenuhi batasan $\sum x_i = K$. Jika solusi terbaik melanggar batasan, kita dapat melakukan *post-selection* dengan mengambil solusi terbaik berikutnya dalam distribusi probabilitas yang memenuhi syarat batasan tersebut.

Appendix A Markowitz: Model Portofolio Modern

Model Markowitz, atau dikenal sebagai **Modern Portfolio Theory (MPT)**, diperkenalkan oleh Harry Markowitz pada tahun 1952. Berikut adalah langkah-langkah penurunan rumusnya dari tingkat filosofis hingga menjadi persamaan optimasi biner.

A.1 Fondasi Filosofis dan Aksioma Dasar

Penurunan ini bermula dari beberapa postulat tentang perilaku manusia dan pasar:

A.1.1 Aksioma Rasionalitas (Risk Aversion)

Investasi bukan sekadar mencari keuntungan sebesar-besarnya. Investor diasumsikan rasional: - Jika ada dua aset dengan **return yang sama**, investor akan memilih yang memiliki **risiko lebih rendah**. - Jika ada dua aset dengan **risiko yang sama**, investor akan memilih yang memiliki **return lebih tinggi**.

A.1.2 Konvensi Risiko sebagai Volatilitas

Dalam pandangan Markowitz, risiko bukanlah "kemungkinan bangkrut", melainkan **ketidakpastian**. Secara statistik, ketidakpastian diukur sebagai dispersi dari rata-rata, yaitu **Varians** (σ^2) atau **Deviasi Standar** (σ).

A.1.3 Filosofi Diversifikasi

"Don't put all your eggs in one basket." Markowitz membuktikan secara matematis bahwa menggabungkan aset yang tidak berkorelasi sempurna dapat menurunkan risiko total portofolio tanpa harus mengurangi return yang diharapkan.

A.2 Postulat Matematis: Mean-Variance Optimization

Diberikan N aset, kita mendefinisikan dua variabel statistik utama: 1. **Expected Return (μ):** Nilai rata-rata keuntungan di masa depan. 2. **Kovarians (Σ):** Matriks yang merangkum varians tiap aset (diagonal) dan hubungan pergerakan antar aset (off-diagonal).

Tujuan investor adalah meminimalkan risiko total portofolio:

$$\text{Minimize } \sigma_p^2 = \sum_{i,j} w_i w_j \Sigma_{ij}$$

A.2.1 Konstruksi Matriks Kovarians (Σ)

Risiko portofolio bukan sekadar jumlah risiko aset individu, melainkan bagaimana aset-aset tersebut bergerak bersama. Matriks Σ (ukuran $N \times N$) dirumuskan sebagai:

$$\Sigma = \begin{pmatrix} \sigma_1^2 & \sigma_{12} & \dots & \sigma_{1N} \\ \sigma_{21} & \sigma_2^2 & \dots & \sigma_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{N1} & \sigma_{N2} & \dots & \sigma_N^2 \end{pmatrix}$$

Dimana: 1. **Elemen Diagonal (σ_i^2):** Merupakan **Varians** dari aset i. Ini mewakili risiko intrinsik atau volatilitas aset tersebut. 2. **Elemen Off-Diagonal (σ_{ij}):** Merupakan **Kovarians** antara aset i dan j. Kovarians tidak bisa didapatkan hanya dari σ masing-masing aset, melainkan membutuhkan **Koefisien Korelasi (ρ_{ij})**.

Hubungan matematisnya adalah:

$$\sigma_{ij} = \rho_{ij} \cdot \sigma_i \cdot \sigma_j$$

Di mana: - σ_i, σ_j: Deviasi standar (volatilitas) masing-masing aset. - **Koefisien Korelasi (ρ_{ij}):** Didapatkan dengan menormalisasi kovarians terhadap produk deviasi standar kedua aset:

$$\rho_{ij} = \frac{\sigma_{ij}}{\sigma_i \cdot \sigma_j}$$

- Rentang nilai ρ_{ij} adalah $[-1, 1]$: - **1:** Korelasi positif sempurna (bergerak searah). - **0:** Tidak ada hubungan linear. - **-1:** Korelasi negatif sempurna (bergerak berlawanan arah).

Bagaimana Σ didapatkan? Misalkan kita memiliki matriks return terpusat $\tilde{R}$ berukuran $T \times N$ (dimana setiap elemen sudah dikurangi rata-ratanya, $R_{it} - \bar{R}_i$). Matriks Σ didapat dari perkalian dot product antar kolom aset:

$$\Sigma = \frac{1}{T-1} \tilde{R}^T \tilde{R}$$

Dalam perkalian ini, kolom aset i yang dikalikan dengan dirinya sendiri ($\tilde{R}_i \cdot \tilde{R}_i$) mengisi posisi diagonal sebagai varians, sedangkan perkalian antar kolom berbeda ($\tilde{R}_i \cdot \tilde{R}_j$) mengisi posisi off-diagonal sebagai kovarians.

A.3 Transformasi ke Model Keputusan Biner ($x \in \{0, 1\}$)

Dalam model Markowitz asli, variabelnya adalah bobot ($w \in [0, 1]$). Namun, dalam masalah seleksi aset (seperti pada komputasi kuantum), kita sering menggunakan variabel keputusan biner: - $x_i = 1$: Aset dipilih untuk masuk portofolio. - $x_i = 0$: Aset tidak dipilih.

Maka, fungsi objektif dasarnya adalah:

$$\text{Objektif} = \underbrace{x^T \Sigma x}_{\text{Risiko}} - \underbrace{\lambda \mu^T x}_{\text{Return}}$$

Dimana λ adalah **Risk Aversion Coefficient**. Jika λ besar, investor sangat mengejar return. Jika λ kecil, investor sangat menghindari risiko.

A.4 Penanganan Batasan (The Penalty Term)

Dalam dunia nyata, investasi memiliki batasan (*constraints*), misalnya: "Saya hanya ingin memilih tepat K aset dari N pilihan." Secara matematis:

$$\sum_{i=1}^{N} x_i = K$$

Dalam teknik optimasi konvensional, kita menggunakan metode **Appendix C**. Namun, agar persamaan ini bisa diselesaikan oleh sistem Ising atau QUBO (yang bersifat *unconstrained*), kita harus mengubah "batasan keras" (*hard constraint*) menjadi "penalti lunak" (*soft penalty*).

A.4.1 Mengapa Kuadratik?

Kita menggunakan bentuk selisih kuadrat:

$$\text{Penalti} = A\left(\sum x_i - K\right)^2$$

- Jika $\sum x_i = K$, maka $(K-K)^2 = 0$. Tidak ada penalti (energi minimum). - Jika $\sum x_i \neq K$, maka nilai tersebut akan dikuadratkan (selalu positif) dan dikalikan dengan konstanta A yang besar. Ini akan meningkatkan total energi secara drastis, sehingga sistem akan dipaksa menjauhi solusi yang melanggar batasan ini.

A.5 Formulasi Akhir (The Markowitz Lagrangian)

Dengan menggabungkan semua postulat di atas, kita mendapatkan fungsi energi total (Hamiltonian) yang digunakan dalam optimasi:

$$\min_{x\in\{0,1\}^N} \mathcal{L}(x) = \underbrace{x^T\Sigma x}_{\text{Postulat Risiko}} - \underbrace{\lambda\mu^T x}_{\text{Aksioma Return}} + \underbrace{A\left(\sum_{i=1}^{N} x_i - K\right)^2}_{\text{Konvensi Batasan}}$$

Persamaan ini merangkum seluruh filosofi Markowitz: 1. **Suku pertama** menjaga agar aset yang dipilih tidak saling bergejolak (diversifikasi). 2. **Suku kedua** menarik sistem ke arah keuntungan yang lebih tinggi. 3. **Suku ketiga** memastikan solusi yang ditemukan adalah solusi yang valid sesuai batasan jumlah aset.

Appendix B Risk Aversion Endogen: Pendekatan Sigmoid

B.1 Urgensi: Mengapa Sigmoid?

Dalam model Markowitz statis, λ (bobot return) seringkali dipilih secara subjektif (misal $\lambda = 0.5$). Namun, pasar yang riil bersifat dinamis. Kita membutuhkan fungsi yang bisa mengubah rasio performa aset (μ/σ) menjadi bobot keputusan yang halus namun memiliki batas yang jelas. Fungsi Sigmoid adalah kandidat sempurna karena ia memetakan input tak terbatas menjadi output dalam rentang $(0, 1)$.

B.2 Aksioma & Intuisi: Psikologi Keputusan

Ada tiga aksioma dasar yang melandasi penggunaan fungsi ini: 1. **Aksioma Signal-to-Noise:** Investor tidak melihat keuntungan (μ) secara terisolasi, melainkan selalu membandingkannya dengan derau/risiko (σ). Rasio μ/σ adalah penggerak utama keputusan. 2. **Aksioma Saturasi:** Nafsu terhadap keuntungan tidak tumbuh linear tanpa batas. Ada titik di mana tambahan keuntungan tidak lagi menambah "nafsu" secara signifikan (titik jenuh/saturasi). 3. **Aksioma Batas:** Parameter λ harus berada di antara 0 (fokus total pada risiko) dan 1 (fokus total pada return).

B.3 Reduksionisme: Kasus Minimal ($\mu = \sigma$)

Mari kita lihat apa yang terjadi jika risiko suatu aset tepat sama dengan keuntungan yang diharapkan.

B.3.1 Kondisi Seimbang

Jika $\mu = \sigma$, maka rasio $\mu/\sigma = 1$.

$$\lambda = \frac{1}{1 + e^{-1}} \qquad (1)$$

Visualisasi (1): Jembatan Logika Secara numerik:

$$\lambda \approx \frac{1}{1 + 0.367} \approx 0.731$$

Karena μ/σ positif dan cukup kuat, sistem "condong" untuk mengejar return ($\lambda > 0.5$). Sebaliknya, jika $\mu = 0$ (tidak ada return), maka $\lambda = 0.5$ (netral).

B.4 Jembatan Logika: Formalisme Fungsi Aktivasi

Dalam *Machine Learning*, sigmoid digunakan sebagai gerbang (*gate*). Dalam VQE Portofolio, λ adalah gerbang yang menentukan seberapa besar "angin return" boleh meniup partikel kita keluar dari "lembah risiko".

B.4.1 Persamaan Umum

$$\lambda(\mu, \sigma) = \frac{1}{1 + e^{-(\mu/\sigma)}} \qquad (2)$$

B.5 Derivasi & Indeks Persamaan

Mari kita turunkan bagaimana perubahan kecil pada risiko ($\Delta\sigma$) memengaruhi selera investasi kita.

B.5.1 Sensitivitas Selera terhadap Risiko

Turunan λ terhadap σ menunjukkan seberapa cepat selera kita berubah saat pasar mulai bergejolak:

$$\frac{\partial \lambda}{\partial \sigma} = \frac{e^{-(\mu/\sigma)} \cdot (-\mu/\sigma^2)}{(1 + e^{-(\mu/\sigma)})^2} \qquad (3)$$

Visualisasi (3): Perhitungan Linear Kita sederhanakan menggunakan properti turunan sigmoid $f'(x) = f(x)(1 - f(x))$:

$$\frac{\partial \lambda}{\partial \sigma} = \lambda(1 - \lambda) \cdot \left(\frac{\mu}{\sigma^2}\right)$$

Misalkan pada titik netral $\lambda = 0.5$ dan $\mu/\sigma^2 = 2$:

$$\frac{\partial \lambda}{\partial \sigma} = (0.5)(0.5) \cdot 2 = 0.5$$

Ini menunjukkan bahwa pada kondisi netral, perubahan volatilitas memiliki dampak 50% terhadap pergeseran selera investasi kita.

B.6 Verifikasi & Parameter: Batas Ekstrem

Kita uji model ini pada tiga kondisi pasar yang berbeda:

Kondisi Pasar	Rasio μ/σ	Nilai λ	Perilaku VQE
Pasar Euphoria	$\mu \gg \sigma$	$\lambda \to 1$	Memilih aset return tertinggi, abaikan risiko.
Pasar Netral	$\mu = 0$	$\lambda = 0.5$	Keseimbangan antara keamanan dan cuan.
Pasar Panic	$\mu \ll 0$	$\lambda \to 0$	Memilih aset paling aman (varians terendah).

Visualisasi (6): Contoh Perhitungan Jika pasar sedang jatuh ($\mu = -10, \sigma = 2$):

$$\text{Rasio} = -5 \implies \lambda = \frac{1}{1+e^5} \approx \frac{1}{1+148} \approx 0.006$$

Nilai $\lambda \approx 0$ ini akan membuat Hamiltonian VQE didominasi oleh suku risiko $x^T \Sigma x$.

B.7 Physical Insight: Efek "Termostat" Kuantum

Bayangkan λ sebagai sebuah **termostat** otomatis. 1. Saat pasar "panas" (return tinggi), termostat membuka katup return lebar-lebar ($\lambda \uparrow$). 2. Saat pasar "dingin" (risiko tinggi), termostat menutup katup return dan menyalakan mode aman ($\lambda \downarrow$).

Hubungan dengan Ising Hamiltonian: Parameter λ endogen ini secara otomatis mengatur ulang kekuatan **Field Lokal (h_i)** terhadap **Kopling (J_{ij})**. Tanpa campur tangan manusia, sirkuit kuantum Anda akan menyesuaikan "arah ukurannya" sendiri sesuai dengan iklim data yang masuk.

B.8 Kesimpulan

Dengan menggunakan fungsi sigmoid: - Kita menghindari bias subjektif dalam memilih λ. - Kita memberikan sifat **non-linear** yang lebih mirip dengan perilaku asli manusia. - Kita memastikan bahwa sistem kuantum selalu memiliki skala energi yang konsisten.

Appendix C Lagrange Multiplier dalam Markowitz-QUBO

C.1 Definisi: Mengapa A disebut Bobot Penalti (Lagrange Multiplier)?

Dalam konteks **QUBO (Quadratic Unconstrained Binary Optimization)**, kata kuncinya adalah "*Unconstrained*" (Tanpa Kendala). Algoritma kuantum seperti QAOA atau mesin *annealing* hanya bisa meminimalkan fungsi energi tanpa batasan eksternal.

Namun, dalam dunia nyata, kita memiliki batasan (seperti: "harus memilih tepat K aset"). Untuk memasukkan batasan ini ke dalam fungsi yang "tanpa batasan", kita menggunakan **Metode Penalti**.

- A **sebagai Bobot Penalti**: Menentukan seberapa besar "hukuman" (peningkatan energi) yang diberikan jika solusi melanggar batasan.
- A **sebagai Lagrange Multiplier**: Secara fungsional bertindak seperti pengali λ dalam kalkulus, yang menghubungkan fungsi objektif utama dengan fungsi kendala.

C.2 Hubungan dengan Metode Lagrange Standar

Suku penalti tersebut adalah adaptasi dari **Metode Lagrange Multiplier** untuk optimasi diskrit. Dalam optimasi kontinu standar:

$$\min f(x) \quad \text{dengan kendala} \quad g(x) = 0$$

Dirumuskan menjadi fungsi Lagrangian:

$$\mathcal{L}(x, \lambda) = f(x) + \lambda g(x)$$

Dalam QUBO, kita menggunakan variasi yang disebut **Penalty Method** (bagian dari *Augmented Lagrangian Method*). Perbedaannya, kita menguadratkan kendalanya: $A(g(x))^2$.

Mengapa dikuadratkan? 1. **Selalu Positif**: Jika $g(x) \neq 0$ (baik positif atau negatif), nilai $(g(x))^2$ akan selalu positif, sehingga menambah energi (memberi penalti). 2. **Kesesuaian QUBO**: Bentuk kuadrat memastikan hubungan antar variabel tetap dalam orde dua (kuadratik), yang merupakan syarat format QUBO.

C.3 Penurunan Rumus Penalti

Berikut adalah langkah transformasi dari kendala menjadi suku penalti:

1. **Kendala Asli**: $\sum_{i=1}^{N} x_i = K$ (Jumlah aset yang dipilih harus sama dengan K).
2. **Bentuk Normal Kendala**: $g(x) = \sum_{i=1}^{N} x_i - K = 0$.
3. **Konstruksi Penalti Kuadratik**: Agar nilai minimum fungsi tepat berada di titik di mana $\sum x_i - K = 0$, kita kuadratkan selisihnya:

$$P(x) = A \cdot (g(x))^2 = A \left(\sum_{i=1}^{N} x_i - K \right)^2$$

Jika $\sum x_i = K$, maka $(K - K)^2 = 0$ (Tanpa penalti). Jika terjadi pelanggaran, energi naik sebesar $A \times (\text{error})^2$.

C.4 Fungsi Umum Lagrange Multiplier

Fungsi utama Lagrange Multiplier (A) adalah sebagai **penyeimbang antara dua tujuan yang saling bertentangan**:

1. **Optimalitas (Fungsi Objektif)**: Mencari nilai sekecil atau sebesar mungkin (misal: risiko terkecil atau keuntungan terbesar).
2. **Validitas (Kendala)**: Memastikan solusi tersebut memenuhi syarat yang ditetapkan (misal: jumlah aset pas).

Analogi Sederhana: Bayangkan Anda sedang berbelanja. * **Fungsi Objektif**: Membeli barang sebanyak mungkin (memuaskan keinginan). * **Kendala**: Uang di dompet terbatas. * **Lagrange Multiplier (A)**: Adalah "konsekuensi" jika Anda *over-budget*. Jika A terlalu kecil, Anda mungkin nekat berutang (melanggar kendala). Jika A sangat besar, Anda akan sangat hati-hati agar pengeluaran pas dengan dompet, meskipun keinginan belum sepenuhnya terpenuhi.

Dalam QUBO, nilai A harus dipilih agar cukup besar sehingga kendala tidak dilanggar, tetapi tidak terlalu besar sehingga menutupi detail dari fungsi risiko dan return yang ingin kita optimalkan.

C.5 Strategi Menentukan Nilai A

Menentukan nilai A yang tepat adalah salah satu tantangan utama dalam QUBO. Jika A terlalu kecil, algoritma akan menghasilkan solusi yang melanggar batasan. Jika A terlalu besar, "lanskap energi" menjadi terlalu curam sehingga sulit bagi algoritma untuk menemukan solusi optimal global.

Berikut adalah beberapa pendekatan untuk mendapatkan nilai A:

C.5.1 Pendekatan Teoretis (Upper Bound)

Secara matematis, A harus lebih besar daripada perubahan maksimum yang mungkin terjadi pada fungsi objektif utama (risiko dan return) jika satu variabel berubah.

$$A > \max |\Delta(\text{Risiko} - \text{Return})|$$

Tujuannya adalah memastikan bahwa keuntungan dari "curang" (melanggar batasan) tidak pernah lebih besar daripada kerugian akibat hukuman penalti.

C.5.2 Rule of Thumb (Praktis)

Seringkali, praktisi menggunakan nilai A yang setara atau sedikit lebih besar dari nilai koefisien terbesar dalam matriks kovarians atau return. - Jika Σ_{ij} dan μ_i berada di rentang $[0, 1]$, nilai A sering kali dimulai dari 1 hingga 10.

C.5.3 Pencarian Grid (Grid Search / Hyperparameter Tuning)

Dalam pendekatan ini, A diperlakukan seperti hyperparameter dalam machine learning: 1. Pilih serangkaian nilai (misal: $0.1, 1, 10, 100$). 2. Jalankan optimasi untuk setiap nilai. 3. Pilih nilai A terkecil yang masih memberikan solusi valid (memenuhi $\sum x_i = K$).

C.5.4 Penalti Dinamis (Annealing Schedule)

Beberapa algoritma memulai dengan nilai A yang kecil agar sistem dapat mengeksplorasi ruang solusi secara bebas pada awal proses, kemudian secara bertahap meningkatkan A untuk "memaksa" sistem masuk ke wilayah solusi yang valid di akhir proses.

C.5.5 Normalisasi Fungsi Objektif

Agar pemilihan A lebih konsisten, seringkali suku risiko dan return dinormalisasi terlebih dahulu ke rentang $[0, 1]$. Dengan demikian, nilai A dapat ditentukan secara lebih intuitif (misal: $A = 1.5$ pasti lebih dominan daripada fungsi objektif yang sudah dinormalisasi).

Appendix D Teorema Rayleigh-Ritz: Fondasi Matematis Prinsip Variasi

D.1 Filosofi: Kecenderungan Alam Meminimalkan Energi

Dalam fisika, sistem selalu cenderung menuju kondisi dengan energi terendah (*Ground State*). **Prinsip Variasi** adalah alat matematika yang memungkinkan kita "menebak" kondisi tersebut dengan jaminan bahwa tebakan kita tidak akan pernah lebih rendah dari kenyataan alam semesta.

D.2 Kalkulus Variasi: Mencari Titik Stasioner Energi

Bayangkan energi sistem bukan sebagai angka, melainkan sebagai sebuah **fungsional** $E[\psi]$ yang bergantung pada bentuk fungsi gelombang (atau state) $|\psi\rangle$.

D.2.1 Definisi Fungsional Energi

Energi rata-rata dari sebuah sistem didefinisikan sebagai hasil bagi Rayleigh:

$$E(\psi) = \frac{\langle\psi|\hat{H}|\psi\rangle}{\langle\psi|\psi\rangle} \qquad (1)$$

Visualisasi (1): Jembatan Logika Mengapa kita membagi dengan $\langle\psi|\psi\rangle$? Karena kita ingin memastikan nilai energi tidak bergantung pada "panjang" vektor $|\psi\rangle$ (normalisasi). Jika $|\psi\rangle$ sudah ternormalisasi ($\langle\psi|\psi\rangle = 1$), maka $E(\psi) = \langle\psi|\hat{H}|\psi\rangle$.

D.2.2 Variasi Fungsional ($\delta E = 0$)

Untuk mencari energi minimum, kita lakukan variasi kecil terhadap $|\psi\rangle$ dan menetapkan perubahannya menjadi nol.

$$\delta E = \delta\left[\frac{\langle\psi|\hat{H}|\psi\rangle}{\langle\psi|\psi\rangle}\right] = 0 \qquad (2)$$

Visualisasi (2): Perhitungan Linear (Uraian Variasi) Menggunakan aturan hasil bagi $(u/v)' = (u'v - uv')/v^2$:

$$\delta E = \frac{\delta\langle\psi|\hat{H}|\psi\rangle \cdot \langle\psi|\psi\rangle - \langle\psi|\hat{H}|\psi\rangle \cdot \delta\langle\psi|\psi\rangle}{(\langle\psi|\psi\rangle)^2} = 0$$

Agar hasil bagi ini nol, maka pembilangnya harus nol:

$$\delta\langle\psi|\hat{H}|\psi\rangle \cdot \langle\psi|\psi\rangle = \langle\psi|\hat{H}|\psi\rangle \cdot \delta\langle\psi|\psi\rangle \qquad (3)$$

D.3 Jembatan Logika: Menuju Persamaan Nilai Eigen

Jika kita uraikan variasi pada persamaan (3) terhadap bra $\langle\psi|$:

$$\langle\delta\psi|\hat{H}|\psi\rangle \cdot \langle\psi|\psi\rangle = \langle\psi|\hat{H}|\psi\rangle \cdot \langle\delta\psi|\psi\rangle$$

Pindahkan suku $\langle\psi|\psi\rangle$ ke bawah:

$$\langle\delta\psi|\hat{H}|\psi\rangle = \left(\frac{\langle\psi|\hat{H}|\psi\rangle}{\langle\psi|\psi\rangle}\right)\langle\delta\psi|\psi\rangle \qquad (4)$$

Karena suku dalam kurung adalah E, maka:

$$\langle\delta\psi|(\hat{H}|\psi\rangle - E|\psi\rangle) = 0$$

Karena variasi $\langle\delta\psi|$ bersifat sembarang, maka bagian dalam kurung harus nol:

$$\hat{H}|\psi\rangle = E|\psi\rangle \qquad (5)$$

Kesimpulan Jembatan: Mencari titik stasioner dari fungsional energi $E(\psi)$ identik dengan menyelesaikan persamaan nilai eigen Schrodinger.

D.4 Reduksionisme: Pembuktian $E(\psi) \geq E_0$

Sekarang kita buktikan bahwa tebakan apa pun ($|\psi\rangle$) selalu memberikan energi di atas atau sama dengan *ground state* (E_0).

D.4.1 Ekspansi dalam Basis Eigen

Misalkan $\{|v_n\rangle\}$ adalah set vektor eigen dari $\hat{H}$ dengan energi $E_0 \leq E_1 \leq E_2 \ldots$. Sembarang state $|\psi\rangle$ dapat ditulis sebagai:

$$|\psi\rangle = \sum_n c_n|v_n\rangle \qquad (6)$$

Visualisasi (6): Operasi Matriks Secara linear, $|\psi\rangle$ adalah jumlahan berbobot dari state-state murni (basis eigen):

$$|\psi\rangle = c_0|v_0\rangle + c_1|v_1\rangle + \cdots = \begin{pmatrix} c_0 \\ c_1 \\ \vdots \end{pmatrix}$$

D.4.2 Substitusi ke Rayleigh Quotient

$$E(\psi) = \frac{\sum_n |c_n|^2 E_n}{\sum_n |c_n|^2} \qquad (7)$$

Visualisasi (7): Perhitungan Linear Karena $E_n \geq E_0$ untuk semua n, maka:

$$\sum_n |c_n|^2 E_n \geq \sum_n |c_n|^2 E_0 = E_0 \sum_n |c_n|^2$$

Masukkan kembali ke pembilang persamaan (7):

$$E(\psi) \geq \frac{E_0 \sum_n |c_n|^2}{\sum_n |c_n|^2} = E_0 \qquad (8)$$

D.5 Verifikasi & Parameter: Batas Bawah

Kondisi $\psi\rangle$	Nilai $E(\psi)$	Interpretasi Fisik
$\psi\rangle = v_0\rangle$	$E(\psi) = E_0$	Tebakan tepat mengenai *ground state.*
$\psi\rangle \perp v_0\rangle$	$E(\psi) \geq E_1$	Tebakan tidak mengandung komponen *ground state.*
Sembarang $\psi\rangle$	$E(\psi) > E_0$	Tebakan mengandung "pengotor" dari state eksitasi.

D.6 Physical Insight: "Nature's Compass"

Prinsip variasi bertindak sebagai **kompas** bagi algoritma VQE. 1. Kita membuat sirkuit parametrik $|\psi(\theta)\rangle$. 2. Kita menghitung energi $E(\theta)$ menggunakan QPU. 3. Kita tahu dengan pasti bahwa semakin kecil $E(\theta)$, semakin dekat kita dengan solusi ekonomi optimal (E_0).

Mengapa ini penting untuk portofolio? Karena kita tidak bisa mendiagonalkan matriks kovarians yang sangat besar, kita menggunakan Prinsip Variasi untuk "meraba" dasar lembah energi. Kita tidak perlu tahu di mana dasarnya, kita hanya perlu terus bergerak "ke bawah" sesuai petunjuk Teorema Rayleigh-Ritz.

Appendix E Dekomposisi Hamiltonian: Dari Matriks Global ke String Pauli

E.1 Urgensi Eksplorasi: Masalah "Raksasa" di Ruang Hilbert

Sistem *n-qubit* memiliki ruang status sebesar $2^n \times 2^n$. Untuk 10 aset saja, matriks Hamiltonian berukuran 1024×1024. Komputer kuantum tidak dapat "membaca" atau memproses matriks sebesar ini secara utuh. Hardware kuantum hanya dapat melakukan pengukuran pada basis tertentu (biasanya basis Z). Kita butuh cara untuk memecah informasi global ini menjadi potongan-potongan lokal yang bisa diukur secara paralel.

E.2 Aksioma & Intuisi: Matriks Pauli sebagai "Atom" Informasi

Setiap matriks Hermitian (energi) dapat dibangun dari 4 "batu bata" dasar yang disebut **Matriks Pauli**:

$$I = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}, X = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}, Y = \begin{pmatrix} 0 & -i \\ i & 0 \end{pmatrix}, Z = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix}$$

Aksioma: Matriks Pauli $\{I, X, Y, Z\}$ membentuk basis ortogonal yang lengkap bagi ruang matriks 2×2. Artinya, sembarang matriks energi 1-*qubit* pasti bisa dinyatakan sebagai kombinasi linear dari keempat matriks ini dengan koefisien riil.

E.3 Reduksionisme: Kasus Minimal (1-Qubit)

Mari kita bedah sebuah Hamiltonian 1-*qubit* umum $\hat{H}$:

$$\hat{H} = c_0 I + c_x X + c_y Y + c_z Z \qquad (1)$$

E.3.1 Mencari Koefisien (Proyeksi Trace)

Kita memproyeksikan $\hat{H}$ ke masing-masing basis Pauli menggunakan operasi **Trace** (Tr):

$$c_k = \frac{1}{2}\mathrm{Tr}(\sigma_k \hat{H}) \qquad (2)$$

Visualisasi (2): Perhitungan Matriks (Mencari c_z) Misalkan kita punya Hamiltonian dengan energi state $|0\rangle$ sebesar 3 dan state $|1\rangle$ sebesar 1, maka $\hat{H} = \begin{pmatrix} 3 & 0 \\ 0 & 1 \end{pmatrix}$. Mari kita cari komponen Z:

$$c_z = \frac{1}{2}\mathrm{Tr}\left[\begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix}\begin{pmatrix} 3 & 0 \\ 0 & 1 \end{pmatrix}\right]$$

$$c_z = \frac{1}{2}\mathrm{Tr}\begin{pmatrix} 3 & 0 \\ 0 & -1 \end{pmatrix} = \frac{1}{2}(3 + (-1)) = 1$$

Artinya, energi ini mengandung "gaya" sebesar 1 unit ke arah sumbu Z.

E.4 Jembatan Formalisme & Logika: Banyak Qubit (Many-Body)

Untuk sistem *n-qubit*, kita menggunakan **Produk Tensor** ($\otimes$) untuk membangun basis yang lebih besar.

Jembatan Logika: Jika 1 *qubit* punya 4 basis, maka n *qubit* punya 4^n kombinasi basis (Pauli Strings). Hamiltonian total didekomposisi menjadi jumlahan string:

$$\hat{H} = \sum_{k=1}^{4^n} c_k P_k \qquad (3)$$

Di mana P_k adalah string seperti $Z \otimes I \otimes X \otimes \ldots$.

E.5 Derivasi "Scratchpad" & Indeks Persamaan: Linearitas Ekspektasi

Mengapa dekomposisi ini menjadi kunci VQE? Karena sifat linearitas operator dalam mekanika kuantum:

$$\langle \hat{H} \rangle = \langle \psi | \left(\sum_k c_k P_k \right) | \psi \rangle = \sum_k c_k \langle \psi | P_k | \psi \rangle \qquad (4)$$

Visualisasi (4): Aliran Data Bayangkan kita ingin mengukur energi total: 1. **Klasik:** Komputer menyimpan daftar koefisien $\{c_k\}$ (misal: $c_1 = 0.5, c_2 = -1.2$). 2. **Kuantum:** Hardware mengukur rata-rata string $\langle P_k \rangle$ (misal: $\langle Z_1 Z_2 \rangle = 0.8$). 3. **Hasil:** Kita kalikan secara klasik ($0.5 \times 0.8 + \ldots$) untuk mendapatkan total energi.

Ini memungkinkan kita menghitung energi raksasa hanya dengan melakukan banyak pengukuran kecil yang sederhana.

E.6 Verifikasi & Parameter: Portofolio Markowitz-Ising

Dalam masalah optimasi portofolio, dekomposisi ini sangat efisien karena Hamiltonian Ising hanya memiliki dua jenis "Lego":

Jenis Suku	Komponen Fisik	Pauli String (P_k)	Makna Ekonomi
Suku Linear	$h_i \hat{Z}_i$	$I \otimes \cdots \otimes Z \otimes \cdots \otimes I$	Risiko/Return individu aset i.
Suku Interaksi	$J_{ij} \hat{Z}_i \hat{Z}_j$	$I \otimes \cdots \otimes Z \otimes \cdots \otimes Z \otimes \cdots \otimes I$	Kovarians (hubungan gerak) aset i dan j.

E.7 Analogi "Physical Insight": Spektroskopi Operator

Bayangkan Hamiltonian sebagai **cahaya putih** yang misterius. - Dekomposisi Hamiltonian bertindak seperti **Prisma** yang memecah cahaya tersebut menjadi warna-warna dasar (Pauli Strings). - Komputer kuantum adalah **Detektor** yang hanya bisa melihat satu warna dalam satu waktu. - Dengan mengukur intensitas setiap warna dasar, kita bisa merekonstruksi spektrum energi total dari cahaya tersebut tanpa harus menelan seluruh matari pembentuknya.

E.8 Kesimpulan

Dekomposisi Hamiltonian mengubah masalah **eksponensial** (matriks raksasa) menjadi jumlahan **polinomial** dari pengukuran-pengukuran lokal yang praktis. Tanpa teknik ini, prinsip variasi (Rayleigh-Ritz) tidak akan pernah bisa diimplementasikan pada *hardware* kuantum era *NISQ*.

Appendix F Parameter Shift Rule (PSR)

Parameter Shift Rule adalah teknik fundamental dalam komputasi kuantum variabel (Variational Quantum Circuits) untuk menghitung gradien eksak dari nilai ekspektasi terhadap parameter sirkuit. Berbeda dengan *finite difference* yang hanya memberikan estimasi, PSR memberikan nilai gradien yang analitik dan eksak.

F.1 Sejarah Singkat

Konsep *Parameter Shift Rule* pertama kali diperkenalkan ke komunitas *Quantum Machine Learning* oleh **Mitarai et al.** dalam makalah berjudul *"Quantum Circuit Learning"* pada tahun 2018. Tak lama kemudian, **Schuld et al.** memperluas dan menggeneralisasi metode ini dalam makalah *"Evaluating analytic gradients of quantum circuits on quantum hardware"*.

Sebelum adanya PSR, peneliti sering menggunakan metode *finite difference* (seperti metode Euler) yang memiliki kelemahan pada *hardware* kuantum yang berisik karena ketidakstabilan numerik saat $\Delta\theta$ sangat kecil. PSR memecahkan masalah ini dengan menggunakan pergeseran parameter yang besar (misal $\pi/2$).

F.2 Definisi Matematis

Misalkan kita memiliki fungsi energi (nilai ekspektasi) $E(\theta)$:

$$E(\theta) = \langle\psi|U^\dagger(\theta)MU(\theta)|\psi\rangle$$

Di mana $U(\theta)$ adalah gerbang unitari yang dibangkitkan oleh operator Pauli σ (seperti X, Y, Z):

$$U(\theta) = \exp\left(-i\frac{\theta}{2}\sigma\right)$$

Persamaan *Parameter Shift Rule* menyatakan bahwa turunan $E(\theta)$ terhadap θ adalah:

$$\frac{\partial E(\theta)}{\partial\theta} = \frac{1}{2}\left[E\left(\theta + \frac{\pi}{2}\right) - E\left(\theta - \frac{\pi}{2}\right)\right]$$

F.3 Penurunan Rumus (Derivation)

Mari kita turunkan secara bertahap menggunakan sifat-sifat matriks Pauli.

F.3.1 Turunan Langsung

Gunakan aturan perkalian (product rule) pada $E(\theta)$:

$$\frac{\partial E}{\partial\theta} = \langle\psi|\frac{\partial U^\dagger}{\partial\theta}MU|\psi\rangle + \langle\psi|U^\dagger M\frac{\partial U}{\partial\theta}|\psi\rangle$$

Karena $U(\theta) = e^{-i\frac{\theta}{2}\sigma}$, maka:

$$\frac{\partial U}{\partial\theta} = -\frac{i}{2}\sigma U(\theta), \quad \frac{\partial U^\dagger}{\partial\theta} = \frac{i}{2}U^\dagger(\theta)\sigma$$

Substitusikan ke persamaan turunan:

$$\frac{\partial E}{\partial \theta} = \langle\psi| \left(\frac{i}{2}U^\dagger\sigma\right) MU|\psi\rangle + \langle\psi|U^\dagger M \left(-\frac{i}{2}\sigma U\right)|\psi\rangle$$

$$\frac{\partial E}{\partial \theta} = \frac{i}{2}\langle\psi(\theta)|\sigma M - M\sigma|\psi(\theta)\rangle$$

$$\frac{\partial E}{\partial \theta} = \frac{i}{2}\langle\psi(\theta)|[\sigma, M]|\psi(\theta)\rangle \quad \ldots(1)$$

F.3.2 Ekspansi Pergeseran Parameter

Gunakan identitas Euler untuk operator Pauli ($\sigma^2 = I$):

$$U(s) = e^{-i\frac{s}{2}\sigma} = \cos\left(\frac{s}{2}\right) I - i\sin\left(\frac{s}{2}\right)\sigma$$

Evaluasi $E(\theta + s)$ di mana s adalah pergeseran:

$$E(\theta + s) = \langle\psi(\theta)|U^\dagger(s)MU(s)|\psi(\theta)\rangle$$

`mengapa s hanya berpengaruh pada U saja dan tidak pada $\psi$` > **Penjelasan:** Hal ini didasarkan pada sifat eksponensial operator unitari. Karena $U(\theta+s) = e^{-i\frac{\theta+s}{2}\sigma} = e^{-i\frac{s}{2}\sigma}e^{-i\frac{\theta}{2}\sigma} = U(s)U(\theta)$, maka kita dapat menuliskan: >

$$E(\theta + s) = \langle\psi|U^\dagger(\theta)U^\dagger(s)MU(s)U(\theta)|\psi\rangle$$

> Dengan mendefinisikan $|\psi(\theta)\rangle = U(\theta)|\psi\rangle$, persamaan di atas menjadi: >

$$E(\theta + s) = \langle\psi(\theta)|U^\dagger(s)MU(s)|\psi(\theta)\rangle$$

> Jadi, s dianggap sebagai pergeseran lokal (rotasi tambahan) pada state yang sudah dipreparasi oleh parameter θ.

$$E(\theta + s) = \langle\psi(\theta)|(\cos\frac{s}{2}I + i\sin\frac{s}{2}\sigma)M(\cos\frac{s}{2}I - i\sin\frac{s}{2}\sigma)|\psi(\theta)\rangle$$

Setelah melakukan ekspansi aljabar:

$$E(\theta + s) = \cos^2\frac{s}{2}\langle M\rangle + \sin^2\frac{s}{2}\langle\sigma M\sigma\rangle + \cos\frac{s}{2}\sin\frac{s}{2}\cdot i\langle[\sigma, M]\rangle$$

Dengan cara yang sama untuk $E(\theta - s)$:

$$E(\theta - s) = \cos^2\frac{s}{2}\langle M\rangle + \sin^2\frac{s}{2}\langle\sigma M\sigma\rangle - \cos\frac{s}{2}\sin\frac{s}{2}\cdot i\langle[\sigma, M]\rangle$$

F.3.3 Finalisasi

Kurangi kedua persamaan tersebut:

$$E(\theta + s) - E(\theta - s) = 2\cos\frac{s}{2}\sin\frac{s}{2}\cdot i\langle[\sigma, M]\rangle$$

Gunakan identitas trigonometri $2\sin A\cos A = \sin 2A$:

$$E(\theta + s) - E(\theta - s) = \sin(s)\cdot i\langle[\sigma, M]\rangle \quad \ldots(2)$$

Bandingkan persamaan (2) with persamaan (1). Jika kita pilih $s = \pi/2$:

$$\sin(\pi/2) = 1$$

Maka:

$$E(\theta + \pi/2) - E(\theta - \pi/2) = i\langle[\sigma, M]\rangle$$

Karena dari persamaan (1) kita tahu $\frac{\partial E}{\partial \theta} = \frac{1}{2}\left(i\langle[\sigma, M]\rangle\right)$, maka terbukti bahwa:

$$\frac{\partial E}{\partial \theta} = \frac{1}{2}\left[E\left(\theta + \frac{\pi}{2}\right) - E\left(\theta - \frac{\pi}{2}\right)\right]$$

F.4 Keunggulan PSR

1. **Analitik**: Memberikan gradien yang benar-benar eksak, bukan pendekatan.
2. **Noise Robust**: Karena pergeseran s cukup besar ($\pi/2$), sinyal yang dihasilkan lebih kuat dibandingkan *noise hardware*, berbeda dengan *finite difference* yang butuh s sangat kecil.
3. **Implementasi Mudah**: Tidak memerlukan sirkuit tambahan atau tambahan *qubit*; cukup menjalankan sirkuit yang sama dengan parameter yang berbeda.

Appendix G Ekspansi State dalam Basis Eigen: Mekanisme Konvergensi Kuantum

G.1 Postulat Dasar: Spektrum Operator Hermitian

Dalam mekanika kuantum, Hamiltonian $\hat{H}$ adalah operator linear Hermitian. Berdasarkan **Teorema Spektral** dalam aljabar linear:

Aksioma & Konvensi: 1. **Eigensystem:** Terdapat sekumpulan nilai eigen riil $\{E_n\}$ dan vektor eigen $\{|v_n\rangle\}$ yang memenuhi persamaan:

$$\hat{H}|v_n\rangle = E_n|v_n\rangle$$

2. **Ortonormalitas:** Vektor-vektor eigen ini bersifat ortonormal, yaitu $\langle v_m|v_n\rangle = \delta_{mn}$. 3. **Kelengkapan (Completeness):** Vektor-vektor eigen $\{|v_n\rangle\}$ membentuk basis lengkap untuk ruang Hilbert $\mathcal{H}$.

Filosofi: Basis eigen adalah "bahasa alami" dari Hamiltonian. Sama seperti warna putih yang dapat diuraikan menjadi spektrum warna pelangi, sebuah state kuantum abstrak $|\psi\rangle$ dapat diuraikan menjadi komponen-komponen energi yang menyusunnya.

G.2 Jembatan 1: Prinsip Superposisi dan Resolusi Identitas

Karena $\{|v_n\rangle\}$ adalah basis lengkap, kita dapat menyatakan sembarang state $|\psi\rangle$ sebagai kombinasi linear (superposisi) dari vektor-vektor eigen tersebut.

Alat (Resolusi Identitas): Sebuah identitas operator $\hat{I}$ dapat dinyatakan sebagai jumlah dari semua operator proyeksi ke basis eigen:

$$\hat{I} = \sum_n |v_n\rangle\langle v_n|$$

Jembatan Gagasan: Dengan menyisipkan identitas ke dalam $|\psi\rangle$, kita memproyeksikan state tersebut ke seluruh spektrum Hamiltonian:

$$|\psi\rangle = \hat{I}|\psi\rangle = \sum_n |v_n\rangle\langle v_n|\psi\rangle$$

$$|\psi\rangle = \sum_n \alpha_n|v_n\rangle$$

di mana $\alpha_n = \langle v_n|\psi\rangle$ adalah **amplitudo probabilitas** sistem berada pada tingkat energi E_n.

G.3 Jembatan 2: Normalisasi dan Konservasi Probabilitas

Agar $|\psi\rangle$ merepresentasikan sistem fisik yang nyata, total probabilitas harus bernilai satu.

Derivasi Runtut:

$$\langle\psi|\psi\rangle = \left(\sum_m \alpha_m^*\langle v_m|\right)\left(\sum_n \alpha_n|v_n\rangle\right)$$

Karena sifat ortonormalitas ($\langle v_m|v_n\rangle = \delta_{mn}$), maka:

$$\sum_n |\alpha_n|^2 = 1$$

Jembatan Gagasan: Koefisien $|\alpha_n|^2$ (berdasarkan Aturan Born) menunjukkan bobot kontribusi setiap tingkat energi terhadap state total. Jika $|\alpha_0|^2$ besar, maka state tersebut sangat mirip dengan *ground state*.

G.4 Jembatan 3: Nilai Ekspektasi dalam Representasi Spektral

Bagaimana ekspansi ini membantu kita menghitung energi rata-rata?

Derivasi Energi:

$$\langle E\rangle = \langle\psi|\hat{H}|\psi\rangle = \langle\psi|\hat{H}\left(\sum_n \alpha_n|v_n\rangle\right)$$

Karena $\hat{H}|v_n\rangle = E_n|v_n\rangle$:

$$\langle E\rangle = \left(\sum_m \alpha_m^*\langle v_m|\right)\left(\sum_n \alpha_n E_n|v_n\rangle\right)$$

$$\langle E\rangle = \sum_n E_n|\alpha_n|^2$$

Filosofi Jembatan: Energi yang kita ukur (nilai ekspektasi) adalah **rata-rata tertimbang** dari seluruh spektrum energi Hamiltonian, di mana bobotnya adalah probabilitas $|\alpha_n|^2$ dari ekspansi state kita.

G.5 Aplikasi pada VQE: Mekanisme Konvergensi

Dalam VQE, kita memiliki state parametrik $|\psi(\theta)\rangle$. Berarti amplitudo probabilitasnya juga bergantung pada parameter: $\alpha_n(\theta)$.

Logika Optimasi: 1. **Keadaan Awal:** Saat θ acak, $|\psi(\theta)\rangle$ memiliki komponen di banyak tingkat energi (banyak α_n yang tidak nol). Energi $\langle E\rangle$ akan bernilai tinggi. 2. **Proses Minimisasi:** Algoritma optimasi mengubah θ untuk menurunkan $\langle E\rangle$. 3. **Filter Energi:** Secara matematis, proses ini "membuang" komponen state eksitasi ($n > 0$) dengan cara mengecilkan $|\alpha_n(\theta)|^2$ dan memperbesar $|\alpha_0(\theta)|^2$.

Limit Konvergensi:

$$\lim_{\theta\to\theta^*} \alpha_n(\theta) = \begin{cases} 1 & \text{untuk } n = 0 \\ 0 & \text{untuk } n \neq 0 \end{cases}$$

$$\lim_{\theta\to\theta^*} \langle E\rangle = E_0$$

G.6 Kesimpulan

Ekspansi state adalah alat yang memungkinkan kita melihat "jeroan" dari sirkuit kuantum. Ia membuktikan bahwa menurunkan nilai ekspektasi energi secara numerik setara dengan **menyelaraskan sirkuit kuantum** kita agar tepat berada pada basis eigen energi terendah (*ground state*). Tanpa konsep ekspansi ini, kita tidak akan memiliki justifikasi matematis mengapa VQE dapat menemukan solusi portfolio optimal.

Appendix H Aturan Born: Jembatan Amplitudo ke Probabilitas

Aturan Born (*Born Rule*) adalah postulat dalam mekanika kuantum yang menghubungkan deskripsi matematis abstrak dari sebuah sistem (state vector) dengan hasil pengamatan eksperimental yang nyata. Tanpa aturan ini, kita tidak memiliki cara untuk menginterpretasikan apa arti fisik dari sebuah *qubit*.

H.1 Postulat Dasar: State dalam Ruang Hilbert

Sesuai dengan aksioma mekanika kuantum, sebuah sistem fisik didefinisikan secara lengkap oleh sebuah **vektor keadaan** $|\psi\rangle$ dalam ruang Hilbert kompleks $\mathcal{H}$.

Konvensi Normalisasi: Agar interpretasi probabilitas bersifat konsisten, vektor $|\psi\rangle$ harus ternormalisasi:

$$\langle\psi|\psi\rangle = 1$$

Filosofi: Vektor $|\psi\rangle$ itu sendiri bukanlah entitas yang dapat diamati secara langsung. Ia adalah "gudang potensi" yang menyimpan informasi tentang semua kemungkinan hasil pengukuran. Perubahan $|\psi\rangle$ bersifat deterministik (Persamaan Schrödinger), namun pengukurannya bersifat probabilistik.

H.2 Jembatan 1: Pengukuran sebagai Proyeksi

Dalam mekanika kuantum, setiap instrumen pengukuran mendefinisikan sebuah **basis ortonormal** $\{|n\rangle\}$ dalam ruang Hilbert. Mengukur sistem berarti "memaksa" sistem untuk memilih salah satu dari state basis tersebut.

Alat (Projector Operator): Untuk setiap hasil pengukuran n, terdapat operator proyeksi $\hat{P}_n$:

$$\hat{P}_n = |n\rangle\langle n|$$

Operator ini berfungsi untuk menyaring komponen dari $|\psi\rangle$ yang sejajar dengan hasil n.

H.3 Postulat Born: Definisi Probabilitas

Aturan Born (dinamai dari Max Born, 1926) menyatakan bahwa probabilitas $P(n)$ untuk mendapatkan hasil n saat mengukur $|\psi\rangle$ adalah kuadrat dari magnitudo amplitudo probabilitasnya.

Persamaan Utama:

$$P(n) = |\langle n|\psi\rangle|^2 = \langle\psi|\hat{P}_n|\psi\rangle$$

Jembatan Gagasan: 1. **Amplitudo ($\langle n|\psi\rangle$):** Merupakan angka kompleks yang menunjukkan "seberapa banyak" komponen $|n\rangle$ di dalam $|\psi\rangle$. 2. **Probabilitas ($P(n)$):** Merupakan angka riil non-negatif yang menunjukkan peluang kemunculan hasil tersebut. 3. **Kekekalan Probabilitas:** Karena $\langle\psi|\psi\rangle = 1$ dan $\{|n\rangle\}$ adalah basis lengkap ($\sum \hat{P}_n = I$), maka $\sum P(n) = 1$.

H.4 Jembatan 2: Nilai Ekspektasi dan Statistik Pengukuran

Untuk menghubungkan probabilitas individu dengan nilai rata-rata yang kita cari dalam optimasi (VQE), kita memerlukan konsep **Nilai Ekspektasi**.

Derivasi Runtut: Jika kita mengukur observabel $\hat{A}$ yang memiliki nilai eigen a_n untuk state basis $|n\rangle$, maka rata-rata hasil pengukurannya adalah:

$$\langle \hat{A} \rangle = \sum_n a_n P(n)$$

$$\langle \hat{A} \rangle = \sum_n a_n \langle \psi | n \rangle \langle n | \psi \rangle = \langle \psi | \left(\sum_n a_n |n\rangle\langle n| \right) |\psi\rangle$$

$$\langle \hat{A} \rangle = \langle \psi | \hat{A} | \psi \rangle$$

Filosofi Jembatan: Nilai ekspektasi adalah "rata-rata tertimbang" dari semua kemungkinan hasil berdasarkan Aturan Born. Dalam VQE, kita tidak mencari probabilitas satu per satu, melainkan langsung mengestimasi $\langle \hat{H} \rangle$ melalui statistik *sampling*.

H.5 Jembatan 3: Implementasi pada Komputer Kuantum (Digital)

Pada komputer kuantum, pengukuran dilakukan pada **Basis Komputasi** (Z-basis).

Mekanisme Sampling: Untuk sistem N-*qubit*, basis pengukurannya adalah *bitstring* biner $x \in \{0,1\}^N$. 1. State akhir sirkuit adalah $|\psi(\theta^*)\rangle$. 2. Aturan Born memberikan probabilitas setiap portfolio: $P(x) = |\langle x | \psi(\theta^*) \rangle|^2$. 3. Hardware melakukan **shot-based measurement**: Menjalankan sirkuit M kali. 4. Frekuensi relatif $\frac{\text{counts}(x)}{M}$ akan konvergen ke probabilitas Born $P(x)$ saat $M \to \infty$.

H.6 Ringkasan Aksioma Born

1. **Positifitas:** $P(n) \geq 0$.
2. **Linearitas:** Operator proyeksi bekerja secara linear pada ruang Hilbert.
3. **Collapse (Reduksi Wavefunction):** Setelah pengukuran menghasilkan n, state sistem seketika berubah menjadi $|n\rangle$. Ini adalah alasan mengapa kita memerlukan banyak "shots" untuk merekonstruksi distribusi probabilitas.

Kesimpulan: Aturan Born adalah jembatan terakhir yang mengubah **amplitudo kuantum yang tak terlihat** menjadi **distribusi data yang teramati**. Dalam konteks Markowitz, aturan inilah yang memungkinkan kita memilih aset investasi berdasarkan *bitstring* yang memiliki probabilitas tertinggi di akhir algoritma VQE.