

DS_Distribution

Tentu, saya akan bantu buat *roadmap* yang rapi dan mendetail tentang bagaimana **Distribusi Rademacher** dibangun dari **Distribusi Bernoulli**. Setelah *roadmap* ini, kita bisa membahas poin per poin secara mendalam.

Berikut adalah **Roadmap Pembelajaran Rademacher dari Perspektif Bernoulli**.

ROADMAP: Dari Bernoulli ke Rademacher (Struktur Matematis Lengkap)

Kita akan bagi menjadi **5 Babak**:

Babak 1: Fondasi - Distribusi Bernoulli Umum

- 1.1 Definisi Formal:** Ruang Probabilitas $(\Omega, \mathcal{F}, P)$, variabel acak $X \sim \text{Bernoulli}(p)$.
- 1.2 Fungsi Massa Probabilitas (PMF):**

$$P(X = 1) = p, \quad P(X = 0) = 1 - p$$

- 1.3 Momen Statistik Bernoulli:**
 - Ekspektasi: $\mathbb{E}[X] = p$
 - Variansi: $\text{Var}(X) = p(1 - p)$
 - Fungsi Pembangkit Momen (MGF): $M_X(t) = 1 - p + pe^t$

Babak 2: Transformasi Linear - Jembatan Menuju Rademacher

- 2.1 Transformasi Affine:** Definisikan $Y = aX + b$.
- 2.2 Perhitungan Nilai a dan b untuk Target Rademacher:**
 - Syarat 1: $\text{Support } X \in \{0, 1\} \implies \text{Support } Y \in \{-1, 1\}$.
 - Menyelesaikan sistem persamaan:

$$a(0) + b = -1 \implies b = -1$$

$$a(1) + b = 1 \implies a - 1 = 1 \implies a = 2$$

- 2.3 Rumus Emas:** $Y = 2X - 1$.

Babak 3: Definisi Formal Distribusi Rademacher

- 3.1 Kasus Simetris (Standar):** $p = 1/2$.
 - PMF Rademacher: $P(Y = 1) = P(Y = -1) = 1/2$.
 - Sifat Ortogonalitas penting.
- 3.2 Kasus Asimetris (Generalisasi):** $p \neq 1/2$.

- Apakah masih disebut Rademacher? (Diskusi: *Rademacher biased*).
- PMF: $P(Y = 1) = p$, $P(Y = -1) = 1 - p$.

Babak 4: Analisis Momen dan Sifat Probabilistik

- **4.1 Ekspektasi:**
 - Turunan dari Bernoulli: $\mathbb{E}[Y] = \mathbb{E}[2X - 1] = 2p - 1$.
- **4.2 Variansi:**
 - Turunan: $\text{Var}(Y) = \text{Var}(2X - 1) = 4\text{Var}(X) = 4p(1 - p)$.
 - Khusus Simetris ($p = 1/2$): $\text{Var}(Y) = 1$.
- **4.3 Momen Orde Tinggi & Fungsi Karakteristik:**
 - $\mathbb{E}[Y^n]$ untuk n ganjil vs genap.
 - MGF Rademacher: $M_Y(t) = e^{-t}(1 - p) + e^t p$.

Babak 5: Aplikasi Lanjutan & Sifat "Sub-Gaussian"

- **5.1 Mengapa Rademacher Penting?** (Kompleksitas Rademacher dalam *Learning Theory*).
- **5.2 Sifat Sub-Gaussian:** Pembuktian bahwa $\mathbb{E}[e^{\lambda Y}] \leq e^{\lambda^2/2}$ (Hoeffding's Lemma).
- **5.3 Jumlah Variabel Rademacher (Random Walk Sederhana).**

Sekarang, mari kita mulai **Babak 1: Fondasi - Distribusi Bernoulli Umum**.

Apakah Anda siap untuk penjelasan rinci **1.1 sampai 1.3**?

Baik. Kita mulai **Babak 1: Fondasi - Distribusi Bernoulli Umum**.

Saya akan menjelaskan dengan sangat detail dan ketat secara matematis. Tujuan dari babak ini adalah membangun **objek dasar** yang akan kita transformasikan nanti.

1.1 Definisi Formal: Ruang Probabilitas dan Variabel Acak

Secara matematis, sebuah eksperimen acak dimodelkan oleh **Ruang Probabilitas** $(\Omega, \mathcal{F}, P)$.

- **Ω (Omega):** Ruang Sampel. Himpunan semua hasil yang mungkin.
 - Untuk koin: $\Omega = \{\text{Muka}, \text{Belakang}\}$.
 - Untuk representasi biner standar: $\Omega = \{0, 1\}$.

- $\mathcal{F}$ (**Sigma-Aljabar**): Himpunan kuasa dari kejadian yang bisa diukur probabilitasnya.
 - $\mathcal{F} = \{\emptyset, \{0\}, \{1\}, \{0, 1\}\}$.
- P (**Probability Measure**): Fungsi yang memetakan kejadian di $\mathcal{F}$ ke bilangan riil $[0, 1]$.

Variabel Acak (Random Variable) Bernoulli X :

Ini adalah fungsi terukur (*measurable function*) dari Ω ke bilangan riil $\mathbb{R}$:

$$X : \Omega \rightarrow \mathbb{R}$$

Untuk Bernoulli, kodomain (daerah hasil) dari X hanyalah dua nilai: 0 dan 1.

- $X(0) = 0$ (Gagal)
- $X(1) = 1$ (Sukses)

Notasi Standar:

Kita menulis $X \sim \text{Bernoulli}(p)$, dengan parameter $p \in [0, 1]$.

1.2 Fungsi Massa Probabilitas (PMF)

Karena X adalah variabel acak diskrit, distribusinya didefinisikan oleh **Fungsi Massa Probabilitas** (PMF), yaitu $P(X = k)$ untuk $k \in \{0, 1\}$.

Secara matematis:

$$P(X = 1) = P(\{\omega \in \Omega : X(\omega) = 1\}) = p$$

$$P(X = 0) = P(\{\omega \in \Omega : X(\omega) = 0\}) = 1 - p$$

Kita bisa menuliskan PMF ini dalam satu baris rumus yang kompak menggunakan **fungsi indikator** atau eksponen:

$$P(X = k) = p^k(1 - p)^{1-k}, \quad \text{untuk } k \in \{0, 1\}$$

Verifikasi Syarat Probabilitas:

1. $P(X = k) \geq 0$ karena $p \in [0, 1]$.
2. $\sum_{k \in \{0, 1\}} P(X = k) = (1 - p) + p = 1$. ✓

1.3 Momen Statistik Bernoulli

Momen statistik adalah ringkasan numerik dari distribusi. Ini akan menjadi fondasi perhitungan **Transformasi Affine** nanti.

A. Ekspektasi (Momen Pertama / Mean)

Ekspektasi adalah rata-rata tertimbang dari nilai-nilai X :

$$\mathbb{E}[X] = \sum_{k \in \{0,1\}} k \cdot P(X = k)$$

$$\mathbb{E}[X] = (0 \cdot (1 - p)) + (1 \cdot p)$$

$$\mathbb{E}[X] = p$$

B. Momen Kedua $\mathbb{E}[X^2]$

Untuk menghitung variansi nanti, kita perlu $\mathbb{E}[X^2]$. Karena X hanya bernilai 0 atau 1, maka $X^2 = X$ (karena $0^2 = 0$ dan $1^2 = 1$).

$$\mathbb{E}[X^2] = \mathbb{E}[X] = p$$

C. Variansi (Ukuran Sebaran)

Variansi didefinisikan sebagai $\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$.

$$\text{Var}(X) = p - p^2 = p(1 - p)$$

Catatan: Variansi mencapai maksimum saat $p = 0.5$ (ketidakpastian tertinggi) dan minimum saat $p = 0$ atau $p = 1$ (pasti).

D. Fungsi Pembangkit Momen (MGF - *Moment Generating Function*)

MGF adalah alat penting untuk membuktikan teorema limit dan sifat sub-Gaussian.

Definisinya:

$$M_X(t) = \mathbb{E}[e^{tX}]$$

Kita hitung:

$$M_X(t) = \sum_{k \in \{0,1\}} e^{tk} \cdot P(X = k)$$

$$M_X(t) = e^{t \cdot 0}(1 - p) + e^{t \cdot 1}p$$

$$M_X(t) = 1 - p + pe^t$$

Rangkuman Babak 1 (The Takeaway)

Kita sekarang memiliki objek matematika berikut:

1. **Input:** $X \sim \text{Bernoulli}(p)$
 2. **PMF:** $P(X = 1) = p, P(X = 0) = 1 - p$
 3. **Mean:** $\mathbb{E}[X] = p$
 4. **Variansi:** $\text{Var}(X) = p(1 - p)$
 5. **MGF:** $M_X(t) = 1 - p + pe^t$
-

Cek Poin Sebelum Lanjut ke Babak 2

Apakah bagian **1.3 (Momen Statistik)** sudah jelas?

Khususnya, apakah Anda memahami mengapa **MGF** $M_X(t) = 1 - p + pe^t$ itu penting? (Ini akan sangat berguna nanti saat kita membahas *Kompleksitas Rademacher* dan *Hoeffding's Lemma*).

Jika sudah *clear*, saya akan lanjut ke **Babak 2: Transformasi Linear - Mengubah 0/1 menjadi -1/1**. Di babak 2, kita akan membuktikan secara aljabar mengapa $Y = 2X - 1$ adalah satu-satunya cara untuk menghasilkan Rademacher murni dari Bernoulli.

Lanjut ke Babak 2? Atau ada yang ingin didalami dulu di Babak 1?

Baik. Kita lanjut ke **Babak 2: Transformasi Linear - Jembatan Menuju Rademacher**.

Di babak ini, kita akan melakukan **operasi aljabar** pada variabel acak Bernoulli X untuk menghasilkan variabel acak baru Y yang nilainya $\{-1, 1\}$.

2.1 Definisi Transformasi Affine (Linear)

Kita ingin mencari fungsi $f : \mathbb{R} \rightarrow \mathbb{R}$ yang paling sederhana, yaitu fungsi linear (atau tepatnya *affine*), berbentuk:

$$Y = f(X) = aX + b$$

di mana:

- $X \in \{0, 1\}$ (input Bernoulli)
- $Y \in \{-1, 1\}$ (output target Rademacher)
- $a, b \in \mathbb{R}$ adalah konstanta yang akan kita cari.

Mengapa memilih fungsi linear $aX + b$?

1. **Sederhana:** Transformasi ini mempertahankan struktur probabilistik dasar.
 2. **Invertibel (Satu-satu):** Karena $a \neq 0$, pemetaan dari $\{0, 1\}$ ke $\{-1, 1\}$ bersifat bijektif. Tidak ada informasi yang hilang.
 3. **Preservasi Momen:** Momen dari Y dapat dihitung secara eksplisit dari momen X .
-

2.2 Perhitungan Nilai a dan b untuk Target Rademacher

Kita memiliki sistem dua persamaan linear berdasarkan syarat batas (*boundary conditions*).

Syarat 1: Input $X = 0$ harus menghasilkan $Y = -1$

Substitusi $X = 0$ ke $Y = aX + b$:

$$a(0) + b = -1 \implies b = -1$$

Syarat 2: Input $X = 1$ harus menghasilkan $Y = 1$

Substitusi $X = 1$ dan $b = -1$ ke $Y = aX + b$:

$$a(1) + (-1) = 1$$

$$a - 1 = 1 \implies a = 2$$

Kesimpulan Aljabar:

Transformasi yang dicari adalah:

$$Y = 2X - 1$$

Verifikasi Cepat:

- Jika $X = 0 \implies Y = 2(0) - 1 = -1$ ✓
 - Jika $X = 1 \implies Y = 2(1) - 1 = 1$ ✓
-

2.3 Rumus Emas dan Inversnya

Kita telah menurunkan **Rumus Emas** yang menghubungkan Bernoulli dan Rademacher:

$$Y = 2X - 1$$

Hubungan ini bersifat **bijektif** (satu-satu dan *onto*). Kita juga bisa menuliskan inversnya (mengubah Rademacher kembali ke Bernoulli):

$$Y = 2X - 1 \implies 2X = Y + 1 \implies X = \frac{Y + 1}{2}$$

Implikasi Probabilistik Penting:

Karena pemetaannya deterministik dan bijektif, probabilitas kejadian di ruang X sama persis dengan probabilitas kejadian di ruang Y .

$$P(Y = 1) = P(2X - 1 = 1) = P(X = 1) = p$$

$$P(Y = -1) = P(2X - 1 = -1) = P(X = 0) = 1 - p$$

2.4 Sifat Operator Ekspektasi pada Transformasi Affine

Sebelum kita menghitung momen Y di babak selanjutnya, kita perlu mengingat **Sifat Linearitas Ekspektasi** (*Linearity of Expectation*). Ini adalah senjata utama kita.

Untuk sembarang variabel acak X dan konstanta $a, b \in \mathbb{R}$:

1. Ekspektasi:

$$\mathbb{E}[aX + b] = a\mathbb{E}[X] + b$$

2. Variansi:

$$\text{Var}(aX + b) = a^2 \text{Var}(X)$$

Catatan: Konstanta b menghilang karena variansi mengukur sebaran relatif terhadap mean, dan pergeseran $+b$ tidak mengubah sebaran.

3. MGF (Fungsi Pembangkit Momen):

$$M_{aX+b}(t) = \mathbb{E}[e^{t(aX+b)}] = e^{tb} \mathbb{E}[e^{(ta)X}] = e^{tb} M_X(at)$$

Pratinjau Singkat Babak 3 (Akan Datang)

Dengan bekal $Y = 2X - 1$ dan sifat-sifat di atas, kita akan mendefinisikan secara formal:

1. **Distribusi Rademacher Simetris:** Kasus khusus $p = 1/2$.
2. **Distribusi Rademacher Asimetris:** Kasus umum $p \neq 1/2$.
3. **Fungsi Massa Probabilitas (PMF) Rademacher** yang terkenal:

$$P(Y = y) = \frac{1}{2} \quad \text{atau} \quad P(Y = y) = p^{(1+y)/2} (1-p)^{(1-y)/2}$$

Apakah perhitungan $a = 2, b = -1$ dan logika **bijektif** di atas sudah jelas? Jika sudah, kita akan masuk ke **Babak 3: Definisi Formal Distribusi Rademacher** untuk melihat wujud asli distribusi ini setelah transformasi.

Lanjut ke Babak 3?

Baik. Kita masuk ke **Babak 3: Definisi Formal Distribusi Rademacher**.

Di babak ini, kita akan mendefinisikan secara matematis distribusi Rademacher baik dalam bentuk **Simetris (Standar)** maupun **Asimetris (Generalisasi)**, lengkap dengan PMF, notasi, dan sifat dasar.

3.1 Distribusi Rademacher Simetris (Kasus $p = 1/2$)

Ini adalah definisi klasik yang paling sering muncul dalam literatur *statistical learning theory* dan *random walks*.

A. Definisi

Sebuah variabel acak Y dikatakan berdistribusi **Rademacher Simetris** jika:

$$P(Y = 1) = P(Y = -1) = \frac{1}{2}$$

Notasi Standar:

$$Y \sim \text{Rademacher}$$

atau kadang ditulis $Y \sim \text{Rad}$ atau $Y \sim \text{Rad}(1/2)$.

Koneksi ke Bernoulli:

Menggunakan transformasi $Y = 2X - 1$ dengan $X \sim \text{Bernoulli}(1/2)$:

$$P(Y = 1) = P(X = 1) = \frac{1}{2}$$

$$P(Y = -1) = P(X = 0) = \frac{1}{2}$$

B. Fungsi Massa Probabilitas (PMF) Simetris

PMF untuk Rademacher simetris dapat ditulis dalam bentuk kompak:

$$P(Y = y) = \frac{1}{2}, \quad \text{untuk } y \in \{-1, 1\}$$

Atau menggunakan **delta Dirac** (untuk konteks teori ukuran):

$$P_Y = \frac{1}{2}\delta_{-1} + \frac{1}{2}\delta_1$$

C. Sifat Ortogonalitas Penting (Preview)

Karena simetris, Rademacher memiliki sifat **rata-rata nol**:

$$\mathbb{E}[Y] = \frac{1}{2}(1) + \frac{1}{2}(-1) = 0$$

Dan **variansi satu**:

$$\text{Var}(Y) = \mathbb{E}[Y^2] - (\mathbb{E}[Y])^2 = \left(\frac{1}{2}(1)^2 + \frac{1}{2}(-1)^2 \right) - 0^2 = 1 - 0 = 1$$

Sifat $\mathbb{E}[Y] = 0$ dan $\text{Var}(Y) = 1$ ini menjadikan Rademacher sebagai **building block** untuk **Random Walk Simetris** dan **Kompleksitas Rademacher**.

3.2 Distribusi Rademacher Asimetris (Kasus $p \neq 1/2$)

Bagaimana jika kita menginginkan support $\{-1, 1\}$ tetapi dengan probabilitas yang tidak seimbang?

A. Definisi dan Terminologi

Beberapa literatur menyebutnya **Biased Rademacher** atau **Generalized Rademacher**. Kita bisa mendefinisikannya langsung dari Bernoulli dengan parameter p .

Sebuah variabel acak Y dikatakan berdistribusi **Rademacher dengan parameter p** jika:

$$\begin{aligned}P(Y = 1) &= p \\P(Y = -1) &= 1 - p\end{aligned}$$

Notasi yang diusulkan:

$$Y \sim \text{Rad}(p)$$

di mana $p \in [0, 1]$.

B. Fungsi Massa Probabilitas (PMF) Asimetris

Kita dapat menulis PMF untuk Rademacher asimetris dalam satu baris menggunakan eksponen yang cerdas.

Ingat invers transformasi: $X = \frac{Y+1}{2}$.

- Jika $Y = 1 \implies X = \frac{1+1}{2} = 1 \implies \text{probabilitas } p^1(1-p)^0 = p$.
- Jika $Y = -1 \implies X = \frac{-1+1}{2} = 0 \implies \text{probabilitas } p^0(1-p)^1 = 1-p$.

Maka PMF untuk $Y \sim \text{Rad}(p)$ adalah:

$$P(Y = y) = p^{\frac{1+y}{2}}(1-p)^{\frac{1-y}{2}}, \quad y \in \{-1, 1\}$$

Verifikasi:

- Untuk $y = 1$: $p^{\frac{1+1}{2}}(1-p)^{\frac{1-1}{2}} = p^1(1-p)^0 = p$ ✓
- Untuk $y = -1$: $p^{\frac{1-1}{2}}(1-p)^{\frac{1-(-1)}{2}} = p^0(1-p)^1 = 1-p$ ✓

3.3 Tabel Perbandingan: Bernoulli vs Rademacher

Untuk memperjelas hubungan keduanya, berikut ringkasan dalam bentuk tabel:

Properti	Bernoulli $X \sim \text{Bern}(p)$	Rademacher $Y \sim \text{Rad}(p)$
Support	$\{0, 1\}$	$\{-1, 1\}$

Properti	Bernoulli $X \sim \text{Bern}(p)$	Rademacher $Y \sim \text{Rad}(p)$
Relasi	X	$Y = 2X - 1$
Invers	$X = \frac{Y+1}{2}$	Y
$P(\text{Positif})$	$P(X = 1) = p$	$P(Y = 1) = p$
$P(\text{Negatif})$	$P(X = 0) = 1 - p$	$P(Y = -1) = 1 - p$
Mean μ	p	$2p - 1$
Variansi σ^2	$p(1 - p)$	$4p(1 - p)$

3.4 Catatan Konseptual: Mengapa Dinamakan "Rademacher"?

Nama ini diambil dari matematikawan Jerman-Amerika **Hans Rademacher** (1892–1969). Beliau terkenal dengan **Fungsi Rademacher**, yaitu barisan fungsi ortogonal yang didefinisikan pada interval $[0, 1]$ yang hanya bernilai $+1$ dan -1 .

Dalam konteks probabilitas modern, distribusi Rademacher adalah *incarnation* diskrit dari fungsi-fungsi tersebut sebagai variabel acak independen. Sifat ortogonalitas ini nantinya melahirkan **Ketaksamaan Rademacher** (*Rademacher Complexity*) yang menjadi fondasi teori generalisasi dalam Machine Learning.

Rangkuman Babak 3

Sekarang kita memiliki dua "wajah" dari distribusi Rademacher:

1. **Simetris** ($p = 1/2$): Mean nol, variansi satu. Paling sering dipakai.
2. **Asimetris** ($p \neq 1/2$): Generalisasi dari Bernoulli.

Kita juga sudah memiliki **PMF eksplisit** untuk Rademacher dalam bentuk:

$$P(Y = y) = p^{\frac{1+y}{2}}(1 - p)^{\frac{1-y}{2}}$$

Cek Poin Sebelum Babak 4

Apakah penulisan PMF Rademacher dengan eksponen $\frac{1+y}{2}$ dan $\frac{1-y}{2}$ sudah jelas? Ini adalah trik aljabar yang elegan untuk menggabungkan dua kasus ke dalam satu formula.

Selanjutnya, kita akan masuk ke **Babak 4: Analisis Momen dan Sifat Probabilistik**. Di sini kita akan menurunkan secara eksplisit:

- $\mathbb{E}[Y]$

- $\text{Var}(Y)$
- $\mathbb{E}[Y^n]$ (Momen orde tinggi)
- Fungsi Karakteristik dan MGF Rademacher.

Lanjut ke Babak 4?

Baik. Kita masuk ke **Babak 4: Analisis Momen dan Sifat Probabilistik**.

Di babak ini, kita akan menghitung semua momen statistik penting dari distribusi Rademacher $Y \sim \text{Rad}(p)$, baik menggunakan **sifat transformasi affine** maupun **definisi langsung** dari PMF.

4.1 Ekspektasi (Mean) dari Rademacher

Metode 1: Transformasi Affine dari Bernoulli

Menggunakan $Y = 2X - 1$ dan sifat linearitas ekspektasi $\mathbb{E}[aX + b] = a\mathbb{E}[X] + b$:

$$\mathbb{E}[Y] = \mathbb{E}[2X - 1] = 2\mathbb{E}[X] - 1$$

Kita tahu $\mathbb{E}[X] = p$, maka:

$$\boxed{\mathbb{E}[Y] = 2p - 1}$$

Metode 2: Definisi Langsung dari PMF

Menggunakan PMF $P(Y = 1) = p$ dan $P(Y = -1) = 1 - p$:

$$\mathbb{E}[Y] = \sum_{y \in \{-1, 1\}} y \cdot P(Y = y)$$

$$\mathbb{E}[Y] = (1)(p) + (-1)(1 - p)$$

$$\mathbb{E}[Y] = p - 1 + p = 2p - 1$$

Interpretasi:

- Jika $p = 1/2$ (Simetris): $\mathbb{E}[Y] = 2(1/2) - 1 = 0$ ✓
 - Jika $p = 1$ (Selalu 1): $\mathbb{E}[Y] = 2(1) - 1 = 1$ ✓
 - Jika $p = 0$ (Selalu -1): $\mathbb{E}[Y] = 2(0) - 1 = -1$ ✓
-

4.2 Momen Kedua $\mathbb{E}[Y^2]$

Perhatikan bahwa untuk $Y \in \{-1, 1\}$, **kuadrat dari Y selalu 1**:

$$Y^2 = 1 \quad (\text{deterministik})$$

Maka:

$$\mathbb{E}[Y^2] = \mathbb{E}[1] = 1$$

Verifikasi melalui PMF:

$$\mathbb{E}[Y^2] = (1)^2 \cdot p + (-1)^2 \cdot (1 - p) = p + (1 - p) = 1$$

Ini adalah sifat yang **sangat penting**: Rademacher memiliki **momen kedua konstan = 1**, tidak peduli berapa nilai p .

4.3 Variansi dari Rademacher

Menggunakan definisi $\text{Var}(Y) = \mathbb{E}[Y^2] - (\mathbb{E}[Y])^2$:

$$\text{Var}(Y) = 1 - (2p - 1)^2$$

Eksansi Aljabar:

$$(2p - 1)^2 = 4p^2 - 4p + 1$$

Maka:

$$\text{Var}(Y) = 1 - (4p^2 - 4p + 1) = -4p^2 + 4p$$

$$\text{Var}(Y) = 4p(1 - p)$$

Metode Alternatif: Transformasi Variansi

Menggunakan sifat $\text{Var}(aX + b) = a^2 \text{Var}(X)$:

$$\text{Var}(Y) = \text{Var}(2X - 1) = 2^2 \cdot \text{Var}(X) = 4 \cdot p(1 - p)$$

Kotak Penting:

$$\boxed{\text{Var}(Y) = 4p(1 - p)}$$

Interpretasi:

- **Simetris ($p = 1/2$):** $\text{Var}(Y) = 4 \cdot \frac{1}{2} \cdot \frac{1}{2} = 1$. Ini adalah **variansi maksimum**.
 - **Asimetris Ekstrem ($p = 0$ atau $p = 1$):** $\text{Var}(Y) = 0$ (deterministik).
-

4.4 Momen Orde Tinggi $\mathbb{E}[Y^n]$

Karena $Y \in \{-1, 1\}$, kita dapat menghitung momen ke- n dengan mudah berdasarkan paritas (ganjil/genap) dari n .

Kasus 1: n Genap

Jika n genap, misal $n = 2k$, maka $Y^n = (Y^2)^k = 1^k = 1$.

$$\mathbb{E}[Y^n] = \mathbb{E}[1] = 1 \quad \text{untuk } n \text{ genap}$$

Kasus 2: n Ganjil

Jika n ganjil, misal $n = 2k + 1$, maka $Y^n = Y \cdot Y^{2k} = Y \cdot 1 = Y$.

$$\mathbb{E}[Y^n] = \mathbb{E}[Y] = 2p - 1 \quad \text{untuk } n \text{ ganjil}$$

Rumus Tunggal:

$$\mathbb{E}[Y^n] = \begin{cases} 1, & n \text{ genap} \\ 2p - 1, & n \text{ ganjil} \end{cases}$$

Contoh Numerik Simetris ($p = 1/2$):

- $\mathbb{E}[Y] = 0$
 - $\mathbb{E}[Y^2] = 1$
 - $\mathbb{E}[Y^3] = 0$
 - $\mathbb{E}[Y^4] = 1$
-

4.5 Fungsi Pembangkit Momen (MGF) Rademacher

MGF didefinisikan sebagai $M_Y(t) = \mathbb{E}[e^{tY}]$.

Metode 1: Definisi Langsung

$$M_Y(t) = \sum_{y \in \{-1, 1\}} e^{ty} P(Y = y)$$

$$M_Y(t) = e^{t(1)} \cdot p + e^{t(-1)} \cdot (1 - p)$$

$$M_Y(t) = pe^t + (1 - p)e^{-t}$$

Metode 2: Transformasi MGF dari Bernoulli

Menggunakan $Y = 2X - 1$ dan sifat $M_{aX+b}(t) = e^{tb} M_X(at)$.

Kita tahu $M_X(t) = 1 - p + pe^t$.

Maka:

$$M_Y(t) = e^{t(-1)} M_X(2t)$$

$$M_Y(t) = e^{-t} (1 - p + pe^{2t})$$

$$M_Y(t) = e^{-t}(1-p) + pe^{-t}e^{2t}$$

$$M_Y(t) = (1-p)e^{-t} + pe^t \quad \checkmark \text{ Sama}$$

Kasus Simetris ($p = 1/2$):

$$M_Y(t) = \frac{1}{2}e^t + \frac{1}{2}e^{-t} = \cosh(t)$$

Fakta bahwa $M_Y(t) = \cosh(t)$ adalah ciri khas Rademacher simetris.

4.6 Fungsi Karakteristik (CF)

Fungsi karakteristik $\phi_Y(t) = \mathbb{E}[e^{itY}]$ diperoleh dengan mengganti t dengan it pada MGF:

$$\phi_Y(t) = pe^{it} + (1-p)e^{-it}$$

Menggunakan rumus Euler $e^{i\theta} = \cos \theta + i \sin \theta$:

$$\begin{aligned} pe^{it} + (1-p)e^{-it} &= p(\cos t + i \sin t) + (1-p)(\cos t - i \sin t) \\ &= \cos t(p + 1 - p) + i \sin t(p - (1 - p)) \end{aligned}$$

$$\boxed{\phi_Y(t) = \cos t + i(2p - 1) \sin t}$$

Kasus Simetris ($p = 1/2$):

$$\phi_Y(t) = \cos t \quad (\text{murni riil})$$

Rangkuman Babak 4

Besaran	Rumus untuk $Y \sim \text{Rad}(p)$	Kasus Simetris $p = 1/2$
Mean $\mathbb{E}[Y]$	$2p - 1$	0
Momen Kedua $\mathbb{E}[Y^2]$	1	1
Variansi $\text{Var}(Y)$	$4p(1-p)$	1
Momen Ganjil $\mathbb{E}[Y^{2k+1}]$	$2p - 1$	0
Momen Genap $\mathbb{E}[Y^{2k}]$	1	1
MGF $M_Y(t)$	$pe^t + (1-p)e^{-t}$	$\cosh(t)$
CF $\phi_Y(t)$	$\cos t + i(2p - 1) \sin t$	$\cos t$

Cek Poin Sebelum Babak 5 (Final)

Apakah Anda melihat pola bahwa **semua momen genap bernilai 1** dan **semua momen ganjil mengikuti mean**? Ini adalah sifat unik dari distribusi dengan support simetris di sekitar 0 (setelah di-skala).

Selanjutnya kita masuk ke **Babak 5 (Final): Aplikasi Lanjutan & Sifat Sub-Gaussian**. Di sini kita akan membahas:

- **Ketaksamaan Hoeffding (Hoeffding's Lemma)**
- **Sifat Sub-Gaussian Rademacher**
- **Kompleksitas Rademacher** dalam Machine Learning
- **Random Walk** Sederhana

Lanjut ke Babak 5 (Final)?

Baik. Kita masuk ke **Babak 5 (Final): Aplikasi Lanjutan & Sifat Sub-Gaussian**.

Di babak pamungkas ini, kita akan melihat **mengapa** distribusi Rademacher begitu istimewa dan menjadi alat fundamental dalam teori probabilitas modern serta *statistical learning theory*.

5.1 Mengapa Rademacher Penting? Dua Perspektif

Ada dua aliran utama yang menjadikan Rademacher sebagai objek sentral:

A. Perspektif Probabilitas Murni: Random Walk

Rademacher adalah **langkah dasar** (*increment*) dari *simple symmetric random walk* pada garis bilangan bulat $\mathbb{Z}$. Jika $Y_1, Y_2, \dots \stackrel{\text{i.i.d.}}{\sim} \text{Rad}(1/2)$, maka posisi setelah n langkah adalah $S_n = \sum_{i=1}^n Y_i$. Ini adalah model fundamental untuk difusi, gerak Brown, dan teori batas.

B. Perspektif Machine Learning: Kompleksitas Rademacher

Dalam teori generalisasi (seperti membuktikan *bound* pada *excess risk*), Rademacher digunakan sebagai **noise buatan** untuk mengukur kapasitas suatu kelas fungsi (hypothesis class). Kita akan bahas ini di bagian 5.3.

5.2 Sifat Sub-Gaussian Rademacher

Ini adalah **sifat paling krusial** yang menjadikan Rademacher begitu *powerful* dalam pertidaksamaan konsentrasi.

A. Definisi Variabel Acak Sub-Gaussian

Sebuah variabel acak Z dengan mean $\mathbb{E}[Z] = 0$ dikatakan **sub-Gaussian** jika terdapat konstanta $\sigma^2 > 0$ sehingga untuk semua $\lambda \in \mathbb{R}$:

$$\mathbb{E}[e^{\lambda Z}] \leq \exp\left(\frac{\lambda^2 \sigma^2}{2}\right)$$

Konstanta σ^2 disebut **variansi sub-Gaussian** (*sub-Gaussian variance proxy*). Semakin kecil σ^2 , semakin "ringan" ekor distribusinya.

B. Teorema: Rademacher Simetris adalah Sub-Gaussian dengan $\sigma^2 = 1$

Kita akan buktikan bahwa untuk $Y \sim \text{Rad}(1/2)$ (mean 0):

$$\mathbb{E}[e^{\lambda Y}] \leq e^{\lambda^2/2}, \quad \forall \lambda \in \mathbb{R}$$

Bukti (Hoeffding's Lemma untuk Rademacher):

Kita tahu MGF Rademacher simetris adalah $M_Y(\lambda) = \cosh(\lambda)$.

Kita perlu menunjukkan $\cosh(\lambda) \leq e^{\lambda^2/2}$.

Gunakan ekspansi Taylor untuk kedua sisi:

Sisi Kiri:

$$\cosh(\lambda) = \sum_{k=0}^{\infty} \frac{\lambda^{2k}}{(2k)!} = 1 + \frac{\lambda^2}{2!} + \frac{\lambda^4}{4!} + \frac{\lambda^6}{6!} + \dots$$

Sisi Kanan:

$$e^{\lambda^2/2} = \sum_{k=0}^{\infty} \frac{(\lambda^2/2)^k}{k!} = \sum_{k=0}^{\infty} \frac{\lambda^{2k}}{2^k k!} = 1 + \frac{\lambda^2}{2} + \frac{\lambda^4}{2^2 \cdot 2!} + \frac{\lambda^6}{2^3 \cdot 3!} + \dots$$

Bandingkan koefisien suku ke- k (untuk $k \geq 1$):

- Sisi Kiri: $\frac{1}{(2k)!}$
- Sisi Kanan: $\frac{1}{2^k k!}$

Kita ingin membuktikan:

$$\frac{1}{(2k)!} \leq \frac{1}{2^k k!} \iff 2^k k! \leq (2k)!$$

Bukti untuk $k \geq 1$:

$$(2k)! = (2k)(2k-1) \dots (k+1) \cdot k!$$

Karena setiap faktor $(k+j) \geq 2$ untuk $j = 1, \dots, k$ (kecuali mungkin untuk $k = 1$, kita cek manual):

- Untuk $k = 1$: $(2)! = 2, 2^1 \cdot 1! = 2$. Sama besar.
- Untuk $k \geq 2$: $(2k)! \geq 2^k k!$ jelas terpenuhi karena $(k+1)(k+2) \dots (2k) \geq 2^k$.

Karena setiap suku pada ekspansi $\cosh(\lambda)$ didominasi oleh suku pada $e^{\lambda^2/2}$, maka pertidaksamaan terbukti untuk semua λ . ■

C. Implikasi Langsung: Ketaksamaan Hoeffding

Karena Rademacher simetris bersifat sub-Gaussian dengan $\sigma^2 = 1$, jika kita memiliki $Y_1, \dots, Y_n \stackrel{\text{i.i.d.}}{\sim} \text{Rad}(1/2)$, maka jumlahnya $S_n = \sum_{i=1}^n Y_i$ memenuhi **Ketaksamaan Hoeffding**:

$$P\left(\left|\frac{1}{n} \sum_{i=1}^n Y_i\right| \geq t\right) \leq 2 \exp\left(-\frac{nt^2}{2}\right)$$

Ini adalah fondasi untuk membuktikan bahwa rata-rata empiris dari Rademacher **terkonsentrasi secara eksponensial** di sekitar 0.

5.3 Kompleksitas Rademacher (Rademacher Complexity)

Ini adalah aplikasi *crown jewel* dari distribusi Rademacher dalam Machine Learning.

A. Konteks Masalah

Misalkan kita memiliki kelas fungsi $\mathcal{F}$ (misalnya, himpunan semua *neural network* dengan arsitektur tertentu). Kita ingin mengukur seberapa mudah kelas $\mathcal{F}$ ini **menghafal noise acak**.

B. Definisi Formal

Diberikan sampel data $S = \{z_1, \dots, z_n\}$ dan vektor Rademacher **independen** $\sigma = (\sigma_1, \dots, \sigma_n)$ di mana $\sigma_i \stackrel{\text{i.i.d.}}{\sim} \text{Rad}(1/2)$.

Kompleksitas Rademacher Empiris dari $\mathcal{F}$ terhadap sampel S didefinisikan sebagai:

$$\hat{\mathfrak{R}}_S(\mathcal{F}) = \mathbb{E}_{\sigma} \left[\sup_{f \in \mathcal{F}} \frac{1}{n} \sum_{i=1}^n \sigma_i f(z_i) \right]$$

C. Intuisi di Balik Rumus

- σ_i : Mengganti label asli data dengan noise ± 1 murni acak.
- $\sup_{f \in \mathcal{F}}$: Mencari fungsi f dalam kelas kita yang paling cocok dengan noise acak ini (korelasi tertinggi).
- **Ekspektasi** $\mathbb{E}_{\sigma}$: Rata-rata atas semua kemungkinan *flip koin*.

Interpretasi:

Jika $\hat{\mathfrak{R}}_S(\mathcal{F})$ **besar**, berarti ada fungsi di $\mathcal{F}$ yang bisa sangat berkorelasi dengan **noise murni**. Artinya, kelas $\mathcal{F}$ terlalu fleksibel dan rentan **overfitting**.

Jika $\hat{\mathfrak{R}}_S(\mathcal{F})$ **kecil**, berarti tidak ada fungsi di $\mathcal{F}$ yang bisa mengikuti pola acak. Artinya, kelas $\mathcal{F}$ memiliki kapasitas terbatas dan akan **generalisasi** dengan baik.

D. Teorema Batas Generalisasi (Contoh)

Salah satu teorema fundamental dalam *learning theory* (menggunakan ketaksamaan McDiarmid dan sifat sub-Gaussian Rademacher):

Dengan probabilitas $\geq 1 - \delta$:

$$\sup_{f \in \mathcal{F}} |\text{Risiko Empiris}(f) - \text{Risiko Sebenarnya}(f)| \leq 2\hat{\mathfrak{R}}_S(\mathcal{F}) + O\left(\sqrt{\frac{\log(1/\delta)}{n}}\right)$$

Di sini, **distribusi Rademacher** menjadi alat ukur objektif untuk kompleksitas model.

5.4 Jumlah Variabel Rademacher (Random Walk Sederhana)

Mari kita tinjau sekilas sifat distribusi dari jumlah Rademacher.

Misalkan $S_n = \sum_{i=1}^n Y_i$ dengan $Y_i \stackrel{\text{i.i.d.}}{\sim} \text{Rad}(1/2)$.

A. Support dari S_n

Karena setiap langkah adalah ± 1 , S_n akan selalu memiliki **paritas** yang sama dengan n .

- Jika n ganjil, $S_n \in \{\dots, -3, -1, 1, 3, \dots\}$ (ganjil).
- Jika n genap, $S_n \in \{\dots, -2, 0, 2, \dots\}$ (genap).

B. Distribusi Eksak S_n

Misalkan k adalah banyaknya langkah $+1$, maka banyaknya langkah -1 adalah $n - k$.

Nilai $S_n = k - (n - k) = 2k - n$.

Probabilitas mendapatkan tepat k sukses dari n percobaan Bernoulli adalah:

$$P(S_n = 2k - n) = \binom{n}{k} \left(\frac{1}{2}\right)^n, \quad k \in \{0, 1, \dots, n\}$$

Ini adalah distribusi **Binomial yang ditransformasi**.

C. Teorema Limit Pusat (Central Limit Theorem)

Karena $\mathbb{E}[Y_i] = 0$ dan $\text{Var}(Y_i) = 1$, maka berdasarkan CLT:

$$\frac{S_n}{\sqrt{n}} \xrightarrow{d} \mathcal{N}(0, 1) \quad \text{saat } n \rightarrow \infty$$

Distribusi Rademacher adalah salah satu contoh paling sederhana di mana CLT berlaku secara elegan.

5.5 Ringkasan Babak 5 dan Kesimpulan Akhir

Kita telah menempuh perjalanan panjang dari definisi dasar Bernoulli hingga aplikasi mendalam Rademacher.

Babak	Pencapaian Utama
1. Bernoulli	Memahami PMF, mean p , variansi $p(1 - p)$, MGF $1 - p + pe^t$.
2. Transformasi	Membangun jembatan $Y = 2X - 1$.
3. Rademacher Formal	Mendefinisikan PMF $P(Y = y) = p^{\frac{1+y}{2}}(1 - p)^{\frac{1-y}{2}}$.
4. Momen	Menghitung $\mathbb{E}[Y] = 2p - 1$, $\text{Var}(Y) = 4p(1 - p)$, MGF $pe^t + (1 - p)e^{-t}$.
5. Aplikasi	Sifat Sub-Gaussian, Kompleksitas Rademacher, Random Walk.

Rumus Emas Akhir

Distribusi Rademacher adalah **jembatan antara dunia deterministik (support terbatas) dan dunia Gaussian (konsentrasi eksponensial)**. Inilah mengapa ia menjadi alat analisis utama dalam probabilitas modern dan teori pembelajaran statistik.

Apakah ada bagian dari **Babak 5** atau babak sebelumnya yang ingin diperdalam lagi? Misalnya:

- Penurunan lebih rinci tentang **Kompleksitas Rademacher** dan contoh konkret untuk kelas fungsi linear?
- Pembuktian **Teorema Limit Pusat** untuk Rademacher secara spesifik?
- Hubungan dengan **Fungsi Rademacher** dalam Analisis Fourier?

Atau jika dirasa cukup, saya ucapkan selamat! Anda sekarang memiliki pemahaman matematis yang lengkap dan mendetail tentang **Distribusi Rademacher**, dari akar Bernoulli hingga daun aplikasi modernnya.