3_Replikasi_HE_VQE
PDF (Google Drive)

3_Game_Mod...tification
PDF (Google Drive)

2_Replikas...VQE_Medium
PDF (Google Drive)

aku ingin membuat penelitian econophysics yang menggunakan matriks payoff dari game theory untuk menentukan jenis game dan mengonstruksi persamaan hamiltonian dengan tetap berdasarkan model markowitz. kemudian, dari hamiltonian yang didapat, digunakan metodologi vqe ansatz dengan menggunakan sirkuit dan optimasi pada file "3_Replikasi_HE_VQE.pdf". buatkan aku rencana dari pengambilan 4 aset dari large market cap yang ada di indonesia hingga pengambilan 2 aset terbaik berdasarkan model vqe ansatz nya

Rencana penelitian ini akan mengintegrasikan teori permainan (game theory), econophysics, dan komputasi kuantum (VQE) untuk menyeleksi aset di pasar modal Indonesia. Berikut adalah alur metodologi yang disusun berdasarkan dokumen yang Anda lampirkan:

1. Pemilihan 4 Aset Large Cap (Pasar Modal Indonesia)

Pilih 4 saham dari indeks **LQ45** dengan kapitalisasi pasar terbesar yang mewakili sektor berbeda untuk menjaga diversifikasi awal. Sebagai contoh:

- **BBCA** (Perbankan)
- **ASII** (Otomotif/Konglomerasi)
- **TLKM** (Telekomunikasi)
- **UNVR** (Consumer Goods)

---

2. Konstruksi Matriks Payoff (Model Markowitz)

Alih-alih menggunakan return mentah, kita menggunakan parameter **Markowitz** untuk mengisi matriks payoff antara dua pemain (misal Aset A dan Aset B):

- **Strategi:** Qubit $|0\rangle$ berarti "Pilih Aset" dan $|1\rangle$ berarti "Tidak Pilih".
- **Nilai Payoff:** Hitung fungsi objektif Markowitz untuk setiap kombinasi:

$$f(x_i, x_j) = w\sigma_{ij}x_ix_j - (1-w)\mu_i x_i$$

  Di mana w adalah *risk aversion* (misal 0.5), σ adalah kovarians, dan μ adalah *expected return*.
- **Klasifikasi Game:** Berdasarkan matriks ini, tentukan apakah hubungan antar aset bersifat *Coordination*, *Anti-Coordination*, atau *Prisoner's Dilemma*.

---

3. Pemetaan Hamiltonian Ising

Ubah fungsi biaya Markowitz tersebut menjadi operator Hamiltonian (H) agar bisa dibaca oleh komputer kuantum. Transformasikan variabel biner x_i menjadi operator Pauli-Z (Z_i) dengan rumus:

$$x_i \to \frac{I - Z_i}{2}$$

Hamiltonian akhir akan berbentuk:

$$H = \sum_i h_i Z_i + \sum_{i<j} J_{ij} Z_i Z_j + P(\sum x_i - B)^2$$

- h_i: Mewakili bias dari return aset individu.
- J_{ij}: Mewakili interaksi/korelasi antar aset (dari matriks payoff/QMI).
- P: Term penalti untuk memastikan hanya **2 aset** yang terpilih ($B = 2$).

---

4. Implementasi Hardware-Efficient VQE (HE-VQE)

Gunakan arsitektur dari file `3_Replikasi_HE_VQE.pdf` untuk mencari *Ground State Energy* (energi terendah), yang merepresentasikan portofolio paling optimal.

A. Desain Sirkuit (Ansatz)

Gunakan **Hardware-Efficient Ansatz** yang terdiri dari dua lapisan utama:

1. **Lapisan Rotasi (U_{ROT}):** Gunakan rotasi Euler (R_Z, R_X, R_Z) pada setiap qubit dengan parameter θ yang akan dioptimasi.

2. **Lapisan Entanglement (U_{ENT}):** Gunakan gerbang **CNOT** untuk menghubungkan antar qubit guna menangkap interaksi kuantum (efek korelasi antar aset).

B. Proses Optimasi (SPSA)

Gunakan optimizer **SPSA (Simultaneous Perturbation Stochastic Approximation)** untuk memperbarui parameter θ.

- **Keunggulan:** Hanya butuh **2 pengukuran** per iterasi, sangat efisien untuk menangani *noise* pada data pasar.
- **Output:** Cari distribusi probabilitas tertinggi dari *state* akhir (misal state $|0101\rangle$ berarti aset ke-2 dan ke-4 adalah yang terbaik).

---

5. Analisis Hasil & Penentuan 2 Aset Terbaik

1. **Konvergensi:** Pantau grafik penurunan energi. Jika kurva melandai, sistem telah menemukan titik optimal.
2. **Seleksi:** Ambil *state* dengan probabilitas tertinggi hasil pengukuran sirkuit kuantum.
3. **Validasi:** Bandingkan hasil VQE dengan perhitungan klasikal (Full-CI/Diagonalisasi tepat) untuk melihat besaran error (dalam mHa atau nilai fungsi biaya).

Langkah selanjutnya: Apakah Anda ingin saya membuatkan draf kode Python sederhana menggunakan PennyLane untuk struktur Hamiltonian 4 aset ini?

aku akan mengeksekusinya di antigravity, untuk saat ini, aku ingin bertanya dan mengajukan revisi beberapa hal
1. apakah nilai h_i dapat diperoleh dari matriks payoff pada game theory? jika ya, tambahkan urutan caranya.
2. tambahkan cara mendapatkan nilai J_{ij} mulai dari skema stackelberg, pencarian rata-rata return dengan laplace smoothing, klasifikasi tipe permainan, konstruksi quantum state, mencari von neumann entropy, hingga mendapatkan nilai quantum mutual information sebagaimana pada file "3_Game_Model_Identification.pdf"
3.

Tentu, ini adalah revisi rencana penelitian Anda dengan mengintegrasikan alur *Game Theory* yang lebih mendalam untuk ekstraksi parameter Hamiltonian (h_i dan J_{ij}) sesuai dengan metodologi pada file **"3_Game_Model_Identification.pdf"**.

Berikut adalah langkah-langkah detailnya:

1. Mendapatkan Nilai Bias (h_i) dari Matriks Payoff

Nilai h_i (bias qubit tunggal) merepresentasikan kecenderungan satu aset untuk dipilih berdasarkan performa mandirinya dalam struktur permainan.

- **Urutan Cara:**
  1. **Ekstraksi Payoff:** Dari matriks payoff aset i (sebagai *Leader*), ambil nilai payoff untuk kondisi $P(0,0), P(0,1), P(1,0)$, dan $P(1,1)$.
  2. **Normalisasi Probabilitas:** Gunakan frekuensi kejadian setiap *state* untuk mendapatkan probabilitas marginal.
  3. **Formulasi Bias:** Hitung selisih ekspektasi payoff saat aset dipilih vs tidak dipilih. Berdasarkan referensi dokumen, h_i didapat dari:

     $$h_i = (P_i[1,0] + P_i[1,1]) - (P_i[0,0] + P_i[0,1])$$

     Jika h_i negatif, aset memiliki insentif lebih besar untuk dipilih (energi lebih rendah).

2. Mendapatkan Nilai Interaksi (J_{ij}) melalui Quantum Mutual Information (QMI)

Langkah ini menggantikan korelasi Pearson standar dengan interaksi kuantum yang lebih kompleks.

- **A. Skema Stackelberg & Data:** Tentukan satu aset sebagai *Leader* (L) dan lainnya sebagai *Follower* (F) untuk melihat pengaruh asimetris di pasar.
- **B. Rata-rata Return dengan Laplace Smoothing:** Saat menghitung frekuensi kejadian (n_{ij}) dari 4 kombinasi state ($|00\rangle, |01\rangle, |10\rangle, |11\rangle$), tambahkan konstanta $\alpha = 1$ (Laplace Smoothing) untuk menghindari probabilitas nol:

  $$P(i,j) = \frac{n_{ij} + 1}{N + 4}$$

- **C. Klasifikasi Tipe Permainan:** Bandingkan nilai payoff dalam matriks. Jika $P(0,0) > P(1,0)$ dan $P(1,1) > P(0,1)$, maka diklasifikasikan sebagai *Coordination Game*. Ini menentukan arah insentif interaksi.

- **D. Konstruksi Quantum State:** Bangun *density matrix* (ρ) dari probabilitas gabungan yang didapat:

$$\rho_{LF} = \sum_{i,j \in \{0,1\}} P(i,j)|i,j\rangle\langle i,j|$$

- **E. Von Neumann Entropy:** Hitung entropi untuk sistem gabungan dan masing-masing aset ($S = -Tr(\rho \ln \rho)$):
  1. $S(L,F)$: Entropi gabungan.
  2. $S(L)$ dan $S(F)$: Entropi marginal (setelah melakukan *partial trace*).
- **F. Quantum Mutual Information (QMI) sebagai J_{ij}:** Nilai interaksi J_{ij} didefinisikan sebagai QMI yang menangkap total korelasi (klasik + kuantum):

$$J_{ij} = QMI = S(L) + S(F) - S(L,F)$$

  Nilai QMI inilah yang dimasukkan ke dalam Hamiltonian sebagai koefisien pengali term $Z_i Z_j$.

3. Integrasi ke Persamaan Hamiltonian & HE-VQE

Setelah h_i dan J_{ij} didapat dari langkah di atas, masukkan ke fungsi biaya:

$$H_{cost} = \sum_{i=1}^{4} h_i Z_i + \sum_{i<j} J_{ij} Z_i Z_j + \lambda(\sum_{i=1}^{4} \frac{I - Z_i}{2} - 2)^2$$

- **Eksekusi di Antigravity (Hardware-Efficient Ansatz):** Sirkuit akan menggunakan lapisan rotasi $R_y(\theta)$ dan $R_z(\phi)$ yang diikuti oleh entangler CNOT. Optimizer SPSA akan mencari kombinasi sudut yang meminimalkan nilai ekspektasi $\langle H_{cost} \rangle$.

4. Seleksi 2 Aset Terbaik

1. Jalankan simulasi VQE hingga konvergen (misal 200 iterasi).
2. Lakukan *sampling* dari sirkuit optimal sebanyak 1024 kali (shots).
3. Identifikasi bitstring dengan probabilitas tertinggi. Karena kita menetapkan penalti untuk 2 aset, hasil akan berupa string seperti `1010` (Aset 1 dan 3 terpilih) atau `0110` (Aset 2 dan 3 terpilih).
4. Dua aset dengan nilai "1" pada bitstring terbaik tersebut adalah 2 aset pilihan Anda berdasarkan optimasi HE-VQE.

Catatan Revisi: Penggunaan QMI sebagai J_{ij} sangat kuat karena ia mampu menangkap dependensi non-linear yang seringkali luput dari model Markowitz klasik yang hanya berbasis kovarians.

kombinasi_2

IPYNB (Google Drive)

sekarang, aku ingin mencoba hal baru tapi aku tidak yakin hasilnya akan lebih optimal. untuk optmasi, aku ingin menggunakan game theory sebagaimana fungsi game_theory_optimizer_step pada file "kombinasi_2.ipynb". coba beri aku komentar dan apakah optimasi tersebut dalam lebih relevan daripada spsa atau justru lebih baik menggunakan spsa saja?

Ini adalah analisis kritis mengenai kode optimizer yang Anda ajukan (`game_theory_optimizer_step`) dibandingkan dengan SPSA, dilanjutkan dengan **Rencana Penelitian Lengkap** yang mengintegrasikan Econophysics, Game Theory (Markowitz Payoff), dan VQE.

Bagian 1: Analisis Kritis `game_theory_optimizer_step` vs SPSA

Saya telah menganalisis fungsi `game_theory_optimizer_step` pada file `kombinasi_2.ipynb`. Secara teknis, metode ini adalah variasi dari **Coordinate Descent (Greedy Search)**.

Berikut adalah perbandingan performanya untuk penelitian Anda:

Fitur	**SPSA (Standar VQE)**	**Game Theory Optimizer (Kode Anda)**
Metode	Mengestimasi gradien dengan memperturbasi *semua* parameter sekaligus secara acak.	Mengubah *satu per satu* parameter dan mengecek apakah energi turun (Coordinate Descent).
Biaya Komputasi	**Sangat Efisien:** Hanya butuh **2 eksekusi sirkuit** per iterasi, tidak peduli berapa banyak qubit/parameternya.	**Mahal:** Butuh $2 \times N$ **eksekusi sirkuit** per iterasi (dimana N adalah jumlah parameter). Jika ada 24 parameter, butuh 48 kali run per langkah.
Ketahanan Noise	Tinggi. Didesain khusus untuk komputer kuantum yang "berisik" (NISQ).	Rendah. Jika ada sedikit fluktuasi noise pada satu pengukuran, optimizer bisa salah mengambil langkah ("terjebak").

Fitur	SPSA (Standar VQE)	Game Theory Optimizer (Kode Anda)
Konvergensi	Cenderung mulus melandai menuju *Global Minimum*.	Cenderung patah-patah dan mudah terjebak di *Local Minimum* (karena hanya melihat satu dimensi pada satu waktu).
Relevansi Tema	Standar industri untuk *Quantum Machine Learning*.	Secara filosofis menarik ("Setiap parameter adalah pemain yang mencari Nash Eq"), namun secara matematis kurang optimal untuk fungsi biaya non-konveks.

Ekspor ke Spreadsheet

Rekomendasi: Untuk penelitian Econophysics yang serius, **SPSA jauh lebih relevan dan robust**.

- **Alasan:** VQE bertujuan mencari *Ground State Energy*. Landscape energi kuantum sangat kompleks. Metode `game_theory_optimizer` Anda kemungkinan besar akan macet di energi yang belum optimal (sub-optimal local minima) dan memakan waktu komputasi 10x-50x lebih lama dibanding SPSA.

Saran Jalan Tengah: Gunakan konsep **Game Theory pada Pembentukan Hamiltonian** (Matriks Payoff & Interaksi J_{ij}), tetapi gunakan **SPSA untuk menyelesaikannya**. Ini menjaga validitas model Econophysics Anda sekaligus memastikan efisiensi komputasi kuantumnya.

Bagian 2: Rencana Penelitian (4 Aset Large Cap $\rightarrow$ 2 Terbaik)

Berikut adalah rencana penelitian komprehensif mulai dari seleksi data hingga eksekusi VQE, menggabungkan file `3_Game_Model_Identification.pdf` dan `3_Replikasi_HE_VQE.pdf`.

Tahap 1: Data Acquisition & Pre-Selection (Klasik)

Tujuan: Memilih 4 aset representatif dari Pasar Modal Indonesia (LQ45).

1. **Kriteria Seleksi:** Pilih 4 saham dengan *Market Cap* terbesar dari sektor berbeda untuk diversifikasi (Contoh: BBCA, ASII, TLKM, UNVR).
2. **Preprocessing:**
   - Ambil data penutupan harian (*Daily Close*) selama 1-2 tahun terakhir.
   - Hitung *Daily Log Return*: $R_t = \ln(\frac{P_t}{P_{t-1}})$.
   - Lakukan *Discretization* data menjadi biner (seperti di `3_Game_Model_Identification.pdf`):

- State $|0\rangle$ (Untung/Naik): Jika $R_t > 0$.
- State $|1\rangle$ (Rugi/Turun): Jika $R_t \leq 0$.

Tahap 2: Konstruksi Matriks Payoff (Game Theory x Markowitz)

Tujuan: Menentukan nilai permainan antar aset untuk mendapatkan parameter Hamiltonian.

Alih-alih menggunakan payoff sederhana, kita gunakan **Model Utilitas Markowitz** untuk mengisi sel matriks payoff (2×2) untuk setiap pasangan aset (i, j).

1. **Definisi Payoff Markowitz:** Untuk setiap kombinasi strategi (Pilih/Tidak Pilih), hitung utilitas U:

$$U = (1 - \lambda) \cdot \mu_p - \lambda \cdot \sigma_p$$

   - μ_p: Ekspektasi return gabungan pada kondisi tersebut.
   - σ_p: Risiko (volatilitas) gabungan pada kondisi tersebut.
   - λ: Koefisien *Risk Aversion* (misal $\lambda = 0.5$).
2. **Pengisian Matriks (Untuk Pasangan Aset A dan B):**
   - **Kondisi (0,0):** Kedua aset "Naik". Hitung rata-rata return & risiko saat keduanya positif.
   - **Kondisi (0,1) & (1,0):** Satu naik, satu turun.
   - **Kondisi (1,1):** Keduanya turun.
3. **Ekstraksi Parameter Hamiltonian (h_i dan J_{ij}):** Gunakan metode dari `3_Game_Model_Identification.pdf`:
   - **Bias (h_i):** Dihitung dari selisih probabilitas/payoff marginal masing-masing aset.

$$h_A = (P(A_{turun}) - P(A_{naik}))$$

   - **Interaksi (J_{ij}):** Gunakan **Quantum Mutual Information (QMI)**.
     - Bentuk *Density Matrix* ρ_{AB} dari distribusi probabilitas data historis.
     - Hitung Von Neumann Entropy: $S(\rho) = -Tr(\rho \ln \rho)$.
     - Hitung QMI: $J_{AB} = S(\rho_A) + S(\rho_B) - S(\rho_{AB})$.
     - *Interpretasi:* Jika J_{AB} tinggi, kedua aset bergerak sangat sinkron (Coordination Game).

Tahap 3: Konstruksi Hamiltonian Kuadratik (Ising Model)

Ubah masalah optimasi portofolio menjadi operator energi. Kita ingin memilih tepat 2 aset dari 4.

Hamiltonian total:

$$H_{total} = H_{cost} + H_{constraint}$$

1. **Cost Hamiltonian (Profit & Risk via Game Theory):**

$$H_{cost} = \sum_{i=1}^{4} h_i Z_i + \sum_{i<j} J_{ij} Z_i Z_j$$

   - Z_i: Operator Pauli-Z (merepresentasikan keputusan beli/tidak).
   - h_i: Bias individu (dari Markowitz payoff).
   - J_{ij}: Korelasi kuantum (dari QMI).

2. **Constraint Hamiltonian (Penalty Method):** Agar VQE memilih tepat $K = 2$ aset, tambahkan penalti:

$$H_{constraint} = A \left(\sum_{i=1}^{4} \frac{I - Z_i}{2} - K \right)^2$$

   - A: Konstanta penalti yang besar (misal $A = 10$) agar pelanggaran constraint "mahal" secara energi.

Tahap 4: Eksekusi HE-VQE (Hardware-Efficient)

Jalankan simulasi menggunakan sirkuit dari file `3_Replikasi_HE_VQE.pdf`.

1. **Ansatz (Sirkuit):**
   - Gunakan 4 Qubit (satu untuk tiap aset).
   - **Layer Rotasi:** $R_Y(\theta)$ dan $R_Z(\phi)$ pada tiap qubit.
   - **Layer Entanglement:** CNOT gate berantai ($0 \to 1, 1 \to 2, 2 \to 3, 3 \to 0$) untuk menangkap J_{ij}.
   - Ulangi sebanyak d kali (Depth, misal $d = 2$ atau $d = 3$).
2. **Optimasi (Gunakan SPSA):**
   - Inisialisasi parameter θ secara acak.
   - **Loop:**

1. Ukur ekspektasi energi $\langle H_{total} \rangle$ di sirkuit.
2. Update parameter menggunakan SPSA (hanya 2 evaluasi fungsi).
3. Ulangi hingga energi konvergen (misal 100-200 iterasi).

Tahap 5: Hasil & Analisis

1. **Sampling Akhir:** Jalankan sirkuit optimal 1000 kali (*shots*).
2. **Probabilitas Tertinggi:** Cari *bitstring* yang paling sering muncul.
   - Contoh Hasil: `|1010>` (Artinya Aset 1 dan Aset 3 terpilih, karena qubit ke-0 dan ke-2 bernilai 1).
3. **Validasi:**
   - Hitung Sharpe Ratio portofolio terpilih secara manual.
   - Bandingkan apakah pasangan aset yang dipilih VQE memang memiliki "Quantum Mutual Information" yang mendukung diversifikasi atau koordinasi yang diinginkan.

Rencana ini secara ketat mengikuti metodologi file referensi Anda namun mengganti optimizer "mainan" dengan SPSA yang standar industri agar hasil penelitian Anda valid secara ilmiah.

apakah koefisien risk aversion harus berdasarkan input dari investor? tidak bisakah menetukan nilai risk aversion dari kondisi payoff pada matriks payoff yang telah dibuat?

Sangat bisa. Dalam konteks **Econophysics**, justru lebih elegan jika parameter *risk aversion* (λ) bersifat **endogen** (ditentukan oleh data/sifat sistem) daripada eksogen (input subjektif manusia).

Ini membuat penelitian Anda lebih objektif: Anda tidak "menebak" preferensi investor, melainkan mencari tahu **"seberapa besar pasar menghukum risiko saat ini?"**.

Berikut adalah 2 metode untuk menghitung λ langsung dari data/matriks payoff:

Metode 1: *Critical Risk Aversion* (Pendekatan Teori Permainan)

Ini adalah pendekatan yang paling "fisika". Kita mencari nilai λ di mana terjadi **Transisi Fase** pada strategi permainan (misalnya, kapan permainan berubah dari *Dominant Strategy* menjadi *Coordination Game*).

Konsep: Dalam matriks payoff Markowitz, utilitas adalah $U = (1 - \lambda)\mu - \lambda\sigma$. Kita bisa mencari nilai λ "kritis" (λ_c) yang membuat utilitas memilih aset sama dengan utilitas tidak

memilih aset (titik impas).

Langkahnya:

1. Hitung rata-rata *Expected Return* ($\bar{\mu}$) dan rata-rata *Risk* ($\bar{\sigma}$) dari seluruh aset yang Anda pilih (4 aset).
2. Gunakan rasio variabilitas return terhadap total variabilitas (return + risiko). Rumusnya adalah:

$$\lambda_{implied} = \frac{\bar{\mu}}{\bar{\mu} + \bar{\sigma}}$$

   - **Logika:** Jika pasar sedang *volatile* ($\bar{\sigma}$ tinggi), nilai λ akan mengecil (utilitas risiko mendominasi). Jika pasar *bullish* stabil ($\bar{\mu}$ tinggi), λ akan membesar.
   - *Koreksi:* Seringkali rumus utilitas Markowitz ditulis $U = \mu - \lambda\sigma$. Jika menggunakan bentuk ini, maka $\lambda = \frac{\mu}{\sigma}$. Namun karena Anda menggunakan bentuk terbobot $(1 - \lambda)\mu - \lambda\sigma$, rumus di atas lebih tepat agar λ tetap di rentang $[0, 1]$.

Metode 2: *Adaptive Volatility Scaling* (Pendekatan Statistik)

Metode ini mengasumsikan bahwa *risk aversion* pasar sebanding dengan volatilitas saat ini relatif terhadap volatilitas maksimum historis. Ini menangkap "suasana pasar".

Langkahnya:

1. Ambil data historis aset (misal 1 tahun).
2. Hitung volatilitas (σ_i) masing-masing aset.
3. Tentukan λ untuk setiap pasangan aset (i, j) dalam matriks payoff secara dinamis:

$$\lambda_{ij} = \frac{\sigma_{ij}}{\max(\sigma_{global})}$$

   - σ_{ij}: Risiko gabungan aset i dan j.
   - $\max(\sigma_{global})$: Risiko terbesar yang pernah tercatat dalam periode data tersebut.

Implikasi: Jika volatilitas saat ini mendekati rekor tertingginya, sistem akan otomatis menjadi sangat *risk averse* ($\lambda \approx 1$).

Rekomendasi untuk Penelitian Anda (Metode 3: Titik Keseimbangan Nash)

Saya sarankan Anda menggunakan variasi dari **Metode 1** tetapi diterapkan spesifik pada matriks payoff 2×2 agar relevan dengan *Game Theory*.

Kita ingin λ yang "Fair".

Algoritma:

1. Hitung μ_{net} (Total Return Portofolio jika semua aset naik)
2. Hitung σ_{net} (Total Risiko Portofolio jika semua aset naik)
3. Tetapkan λ sebagai:

$$\lambda = \frac{1}{1 + e^{-(\frac{\mu_{net}}{\sigma_{net}})}}$$

(Ini adalah fungsi Sigmoid. Jika Return >> Risk, $\lambda \to 1$ (Agresif). Jika Risk >> Return, $\lambda \to 0$ (Defensif/Menghindar).

Revisi pada Rencana Tahap 2 (Konstruksi Matriks):

Jangan gunakan $\lambda = 0.5$. Gunakan langkah ini sebelum mengisi matriks:

1. Hitung rata-rata return (μ_{avg}) dan rata-rata standar deviasi (σ_{avg}) dari ke-4 aset.
2. Hitung **Market Sentiment Coefficient**:

$$\lambda_{market} = \frac{\sigma_{avg}}{\mu_{avg} + \sigma_{avg}}$$

*(Catatan: Rumus ini dibalik dari metode 1. Di sini, jika σ besar, λ mendekati 1. Artinya kita memberi bobot lebih pada "Term Risiko" dalam persamaan $(1 - \lambda)\mu - \lambda\sigma$. Ini berarti kita menjadi lebih **Risk Averse**).*

Contoh Perhitungan:

- Misal $\mu_{avg} = 0.05$ (5%)
- Misal $\sigma_{avg} = 0.15$ (15%)
- $$\lambda = \frac{0.15}{0.05 + 0.15} = \frac{0.15}{0.20} = 0.75$$
- Artinya, dalam matriks payoff, Anda akan menghitung:

$$U = (1 - 0.75)\mu - 0.75\sigma = 0.25\mu - 0.75\sigma$$

Penelitian Anda akan berbunyi: *"Parameter risk aversion ditentukan secara endogen sebesar 0.75, merefleksikan kondisi pasar yang memiliki volatilitas 3x lipat dari ekspektasi return."*

Powered by Gemini All Chat Downloader

Ini jauh lebih ilmiah dan kuat argumennya dibanding sekadar "misalkan $\lambda = 0.5$".