Koefisien Korelasi Pearson

Standar Emas Hubungan Linear Bivariat

Koefisien Korelasi Pearson (PCC) adalah ukuran statistik fundamental yang menguantifikasi kekuatan dan arah hubungan linear antara dua variabel kontinu.

Berbeda dengan kovarians yang bergantung pada satuan pengukuran, PCC adalah metrik tanpa dimensi (dimensionless). Ini dicapai dengan membagi kovarians dengan produk simpangan baku, yang secara efektif menormalisasi pengukuran.

Hasilnya adalah indeks standar yang memungkinkan perbandingan langsung antara fenomena yang sangat berbeda—mulai dari hubungan usia dan pendapatan, hingga suhu dan penjualan es krim.

Kekuatan & Arah Hubungan

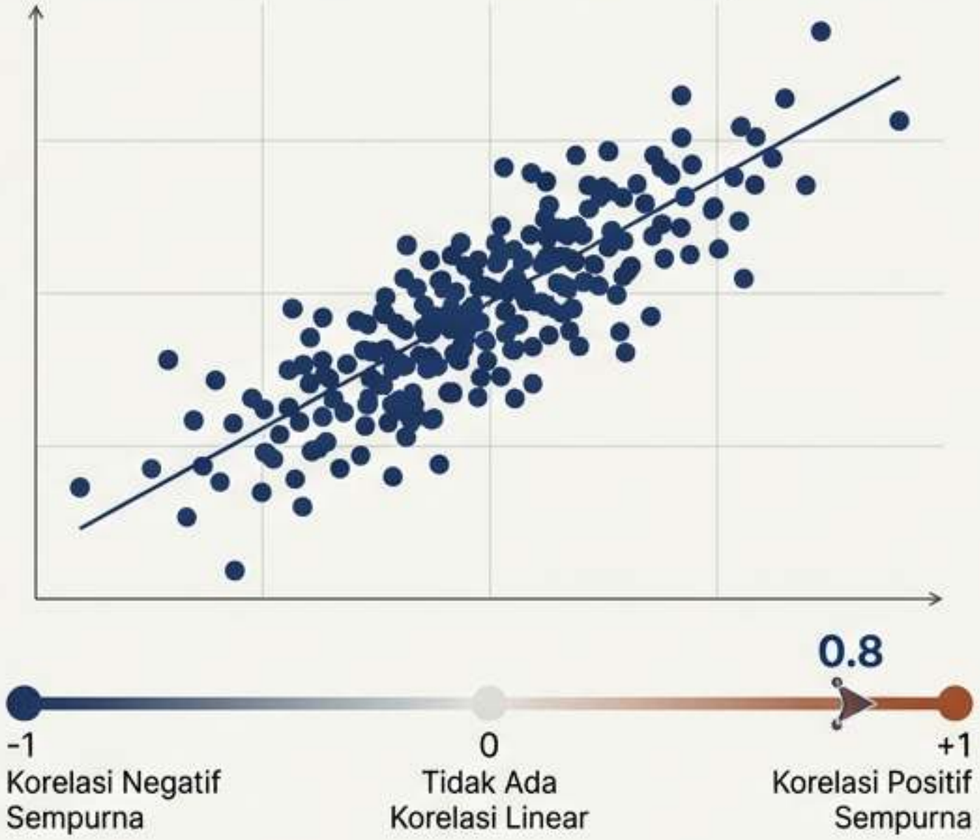

Contoh Korelasi Positif Kuat ($r \approx 0.8$).

NotebookLM

Dari Reversi Galton ke Formalisasi Bravais

Konteks Historis

1844: Auguste Bravais

Menurunkan rumus matematika awal untuk kemungkinan kesalahan, meletakkan dasar bagi analisis bivariat modern.

↓

1880-an: Francis Galton

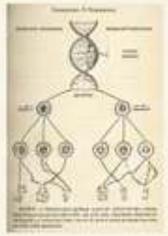

Memperkenalkan konsep biologi "reversi" (yang kemudian menjadi regresi) dan menggunakan simbol *r* untuk "reversion".

↓

1890-an: Karl Pearson

Mengembangkan ide Galton dan memformalkan rumus statistik yang digunakan saat ini. Penamaan "**Pearson**" adalah contoh klasik *Hukum Stigler*: penemuan sering kali dinamai bukan dengan nama penemu aslinya.

Distingsi Konsep

Korelasi (r)

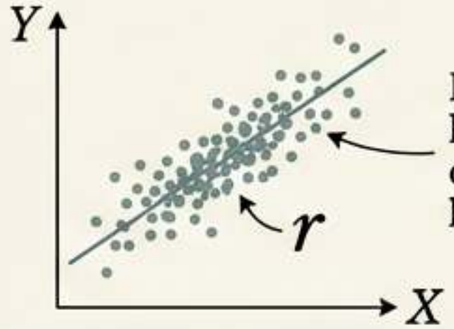

Mengukur kebisingan (*noise*) dan kedekatan titik ke garis.

Slope (Kemiringan)

Kemiringan Curam (*Steep Slope*), $y = 2x$

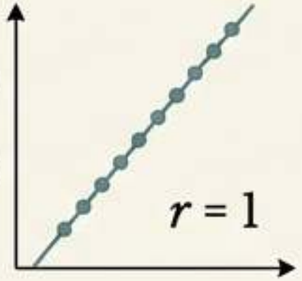

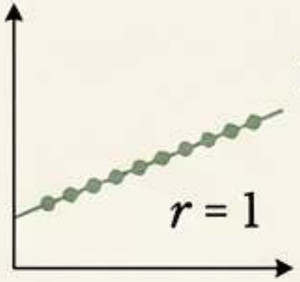

Kemiringan Landai (*Shallow Slope*), $y = 0.5x$

⚠️ **Peringatan:** r bukan kemiringan (*slope*). Kedua grafik ini memiliki korelasi $r = 1$ meskipun kemiringannya berbeda.

NotebookLM

Definisi Populasi: Ekspektasi Momen Produk

Konsep Naratif

Dalam statistik teoretis, kita mendefinisikan korelasi untuk sebuah populasi menggunakan huruf Yunani ρ (rho). Metrik ini disebut 'Product-Moment' karena merupakan nilai ekspektasi (rata-rata) dari produk variabel yang telah dipusatkan (*mean-adjusted*).

Logika Tanda:

Positif: X dan Y berada di sisi rata-rata yang sama (keduanya di atas atau keduanya di bawah).

Negatif: X dan Y berada di sisi rata-rata yang berlawanan.

Pendalaman Matematis

Rumus Utama:

$$\rho_{X,Y} = \frac{\mathrm{cov}(X,Y)}{\sigma_X \sigma_Y}$$

Dekomposisi Ekspektasi:

$$\rho_{X,Y} = \frac{E[(X-\mu_X)(Y-\mu_Y)]}{\sigma_X \sigma_Y}$$

Legenda Variabel:

cov : Kovarians (ukuran variabilitas bersama).

E : Nilai Ekspektasi Matematika.

μ : Rata-rata Populasi (*Mean*).

σ : Simpangan Baku Populasi (*Standard Deviation*).

NotebookLM

Estimasi Sampel: Menghitung r dari Data Riil

Konsep Naratif & Algoritma

Dalam praktik data science, kita bekerja dengan sampel, bukan populasi. Kita menggunakan simbol r sebagai estimator untuk ρ.

Secara komputasi, rumus ini sering diatur ulang untuk efisiensi algoritma (penghitungan 'single-pass'), namun ini membawa risiko ketidakstabilan numerik (*floating point errors*) jika varians data sangat kecil dibandingkan rata-ratanya.

Pendalaman Matematis

1. Definisi Formal (Sample Mean Based):

$$r_{xy} = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2}\sqrt{\sum_{i=1}^{n}(y_i - \bar{y})^2}}$$

2. Bentuk 'Standard Score' (Intuitif):

$$r_{xy} = \frac{1}{n-1}\sum_{i=1}^{n}\left(\frac{x_i - \bar{x}}{s_x}\right)\left(\frac{y_i - \bar{y}}{s_y}\right)$$

Keterangan:
n : Ukuran sampel.
$\bar{x}, \bar{y}$: Rata-rata sampel.
s_x, s_y : Simpangan baku sampel.

NotebookLM

Interpretasi Geometris: Korelasi sebagai Kosinus Sudut

Konsep Ruang Vektor

Jika kita membayangkan data X dan Y sebagai dua vektor dalam ruang berdimensi-N (dimana N adalah jumlah observasi). Apabila data telah Apabila data telah **dipusatkan** (centered) dengan mengurangi rata-ratanya, maka Koefisien Korelasi Pearson (r) secara harfiah adalah **kosinus dari sudut** θ di antara kedua vektor tersebut.

$$r = \cos\theta = \frac{\mathbf{x} \cdot \mathbf{y}}{\|\mathbf{x}\|\,\|\mathbf{y}\|}$$

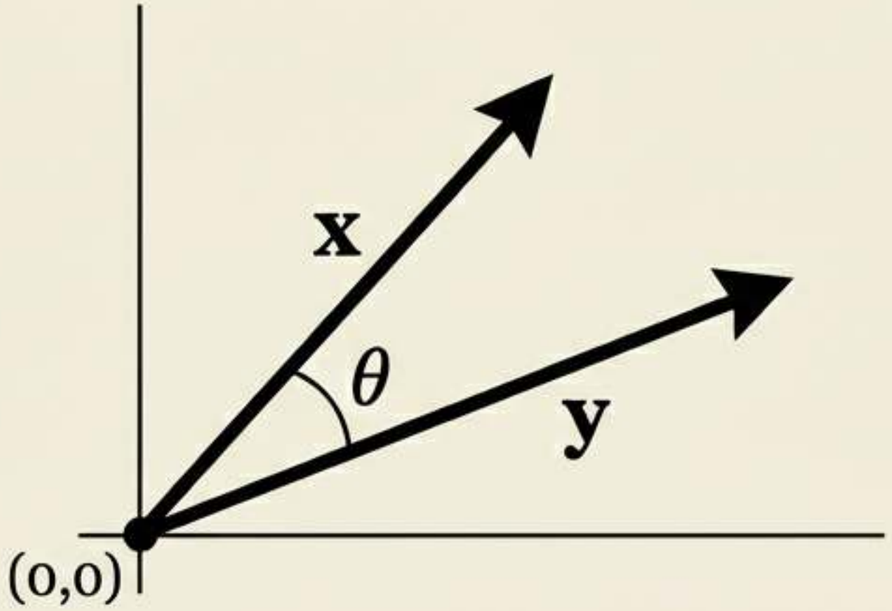

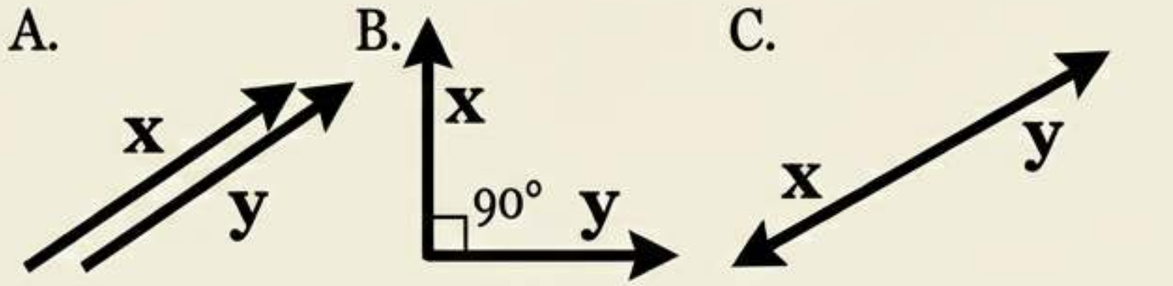

$\theta = 0° \rightarrow \cos(0) = 1$ (Korelasi Sempurna)

$\theta = 90° \rightarrow \cos(90) = 0$ (Tidak Berkorelasi)

$\theta = 180° \rightarrow \cos(180) = -1$ (Korelasi Negatif Sempurna)

NotebookLM

Menginterpretasikan Magnitudo dan Arah

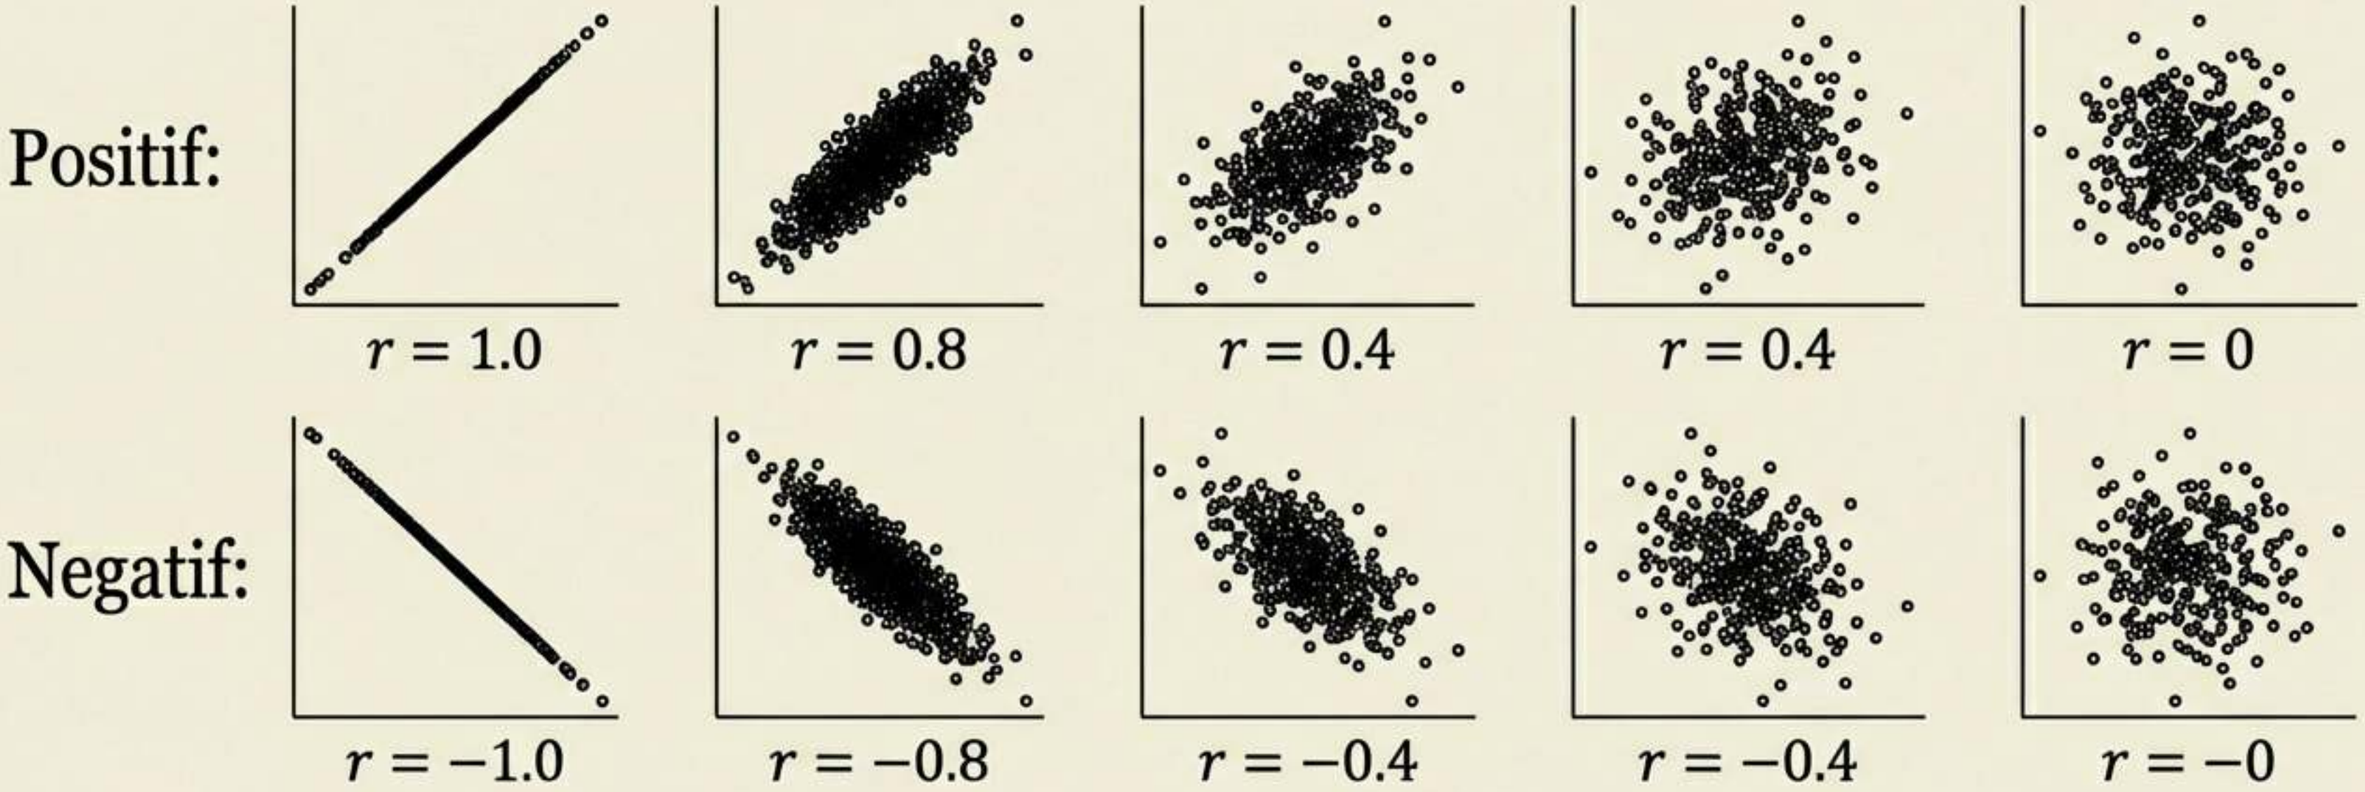

Panduan Interpretasi:

- **Tanda (+/-):** Menunjukkan arah hubungan. Positif berarti Y naik seiring X naik.
- **Nol (0):** Menunjukkan ketiadaan hubungan *linear*. Pola non-linear (seperti parabola) mungkin tetap memiliki $r = 0$.
- **Konteks:** Nilai $r = 0.8$ bisa dianggap 'rendah' dalam fisika presisi, namun 'sangat tinggi' dalam psikometri.

NotebookLM

Pearson dalam Regresi Kuadrat Terkecil

Dekomposisi Varians

Hubungan antara korelasi dan prediksi sangat erat. Kuadrat dari korelasi sampel (r^2) dikenal sebagai **Koefisien Determinasi**. R^2 mewakili proporsi varians pada variabel dependen Y yang dapat 'dijelaskan' oleh model linear dari X.

$$r^2 = \frac{SS_{\text{reg}}}{SS_{\text{tot}}}$$

(Sum of Squares Regression dibagi Total Sum of Squares).

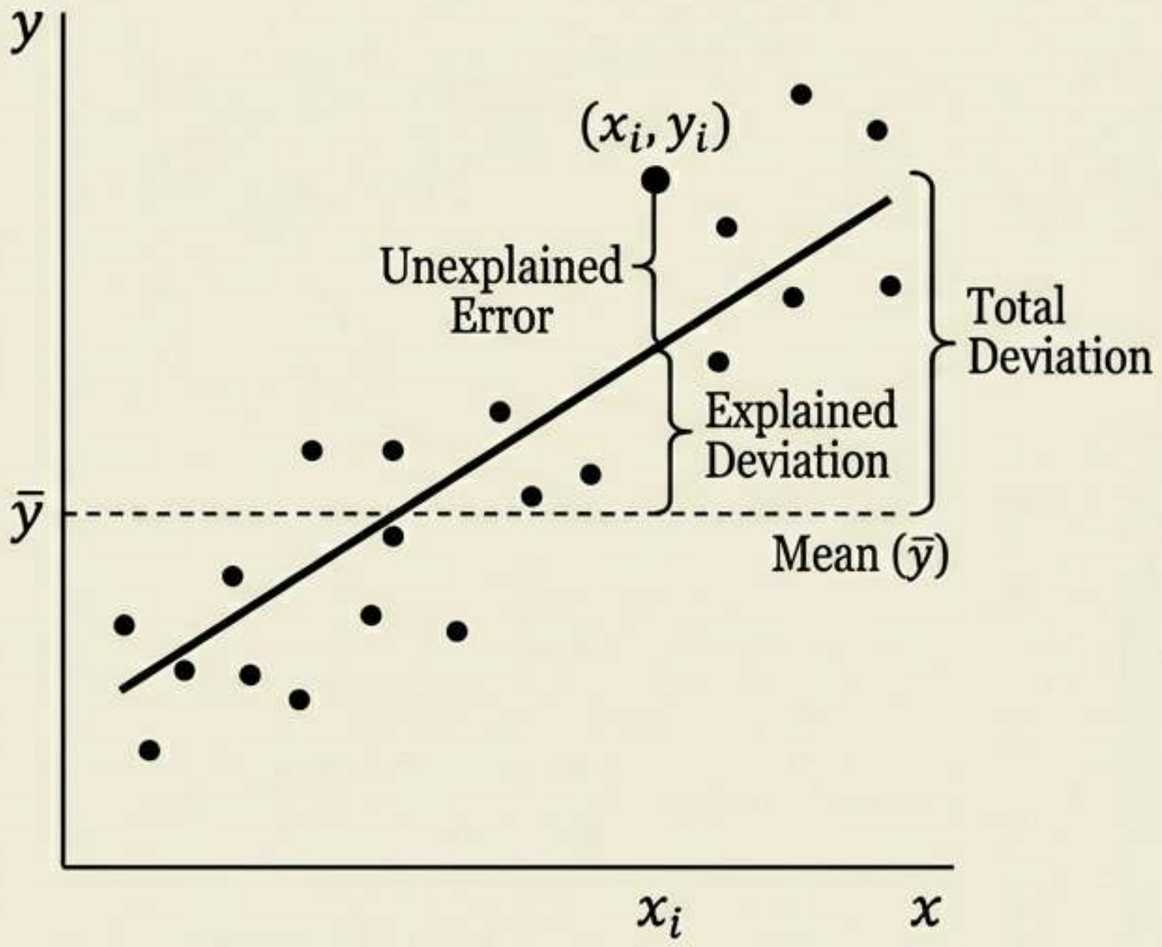

Total Varians = Explained Varians + Unexplained Error

NotebookLM

Inferensi Statistik: Menguji Signifikansi

Apakah nilai $\rho \neq 0$ secara nyata atau hanya kebetulan?

Uji Parametrik

Uji-t Student

Untuk data yang diasumsikan berdistribusi normal bivariat, kita menguji Hipotesis Nol ($\rho = 0$) menggunakan statistik t:

$$t = r\sqrt{\frac{n-2}{1-r^2}}$$

Dengan derajat kebebasan df = n-2. Semakin besar sampel (n), semakin mudah bagi korelasi kecil untuk dianggap signifikan secara statistik.

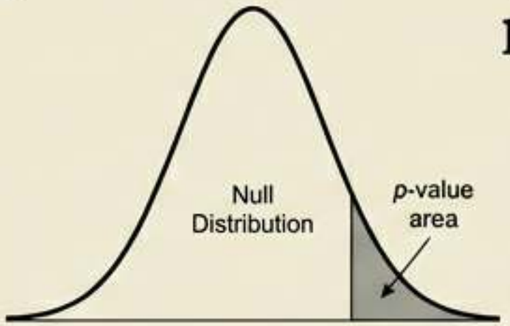

Pendekatan Non-Parametrik

Uji Permutasi (Permutation Test)

Metode komputasi modern yang tidak bergantung pada asumsi normalitas.

1. **Shuffle**: Acak ulang pasangan (x, y) ribuan kali untuk merusak hubungan asli.
2. **Hitung**: Hitung r untuk setiap data acak ini untuk membangun 'distribusi nol'.
3. **Bandingkan**: Seberapa sering r acak lebih ekstrem daripada r observasi? Proporsi ini adalah *p-value*.

NotebookLM

Transformasi Fisher & Interval Kepercayaan

Masalah & Solusi

Distribusi sampling r menjadi miring (*skewed*) saat korelasi populasi mendekati ±1, membuat estimasi interval kepercayaan standar menjadi tidak valid.

Solusinya adalah **Transformasi Fisher** (z'), yang mengubah distribusi r menjadi mendekati normal, menstabilkan varians.

Matematika Transformasi

1. **Transformasi Maju** ($r \to z'$):

$$z' = \frac{1}{2} \ln \left(\frac{1+r}{1-r} \right) = \operatorname{artanh}(r)$$

2. **Standard Error**:

$$SE_{z'} \approx \frac{1}{\sqrt{n-3}}$$

3. **Transformasi Balik** ($z' \to r$): Setelah menghitung interval kepercayaan dalam skala z', kembalikan ke skala korelasi:

$$r = \tanh(z')$$

NotebookLM

Sensitivitas dan Robustness

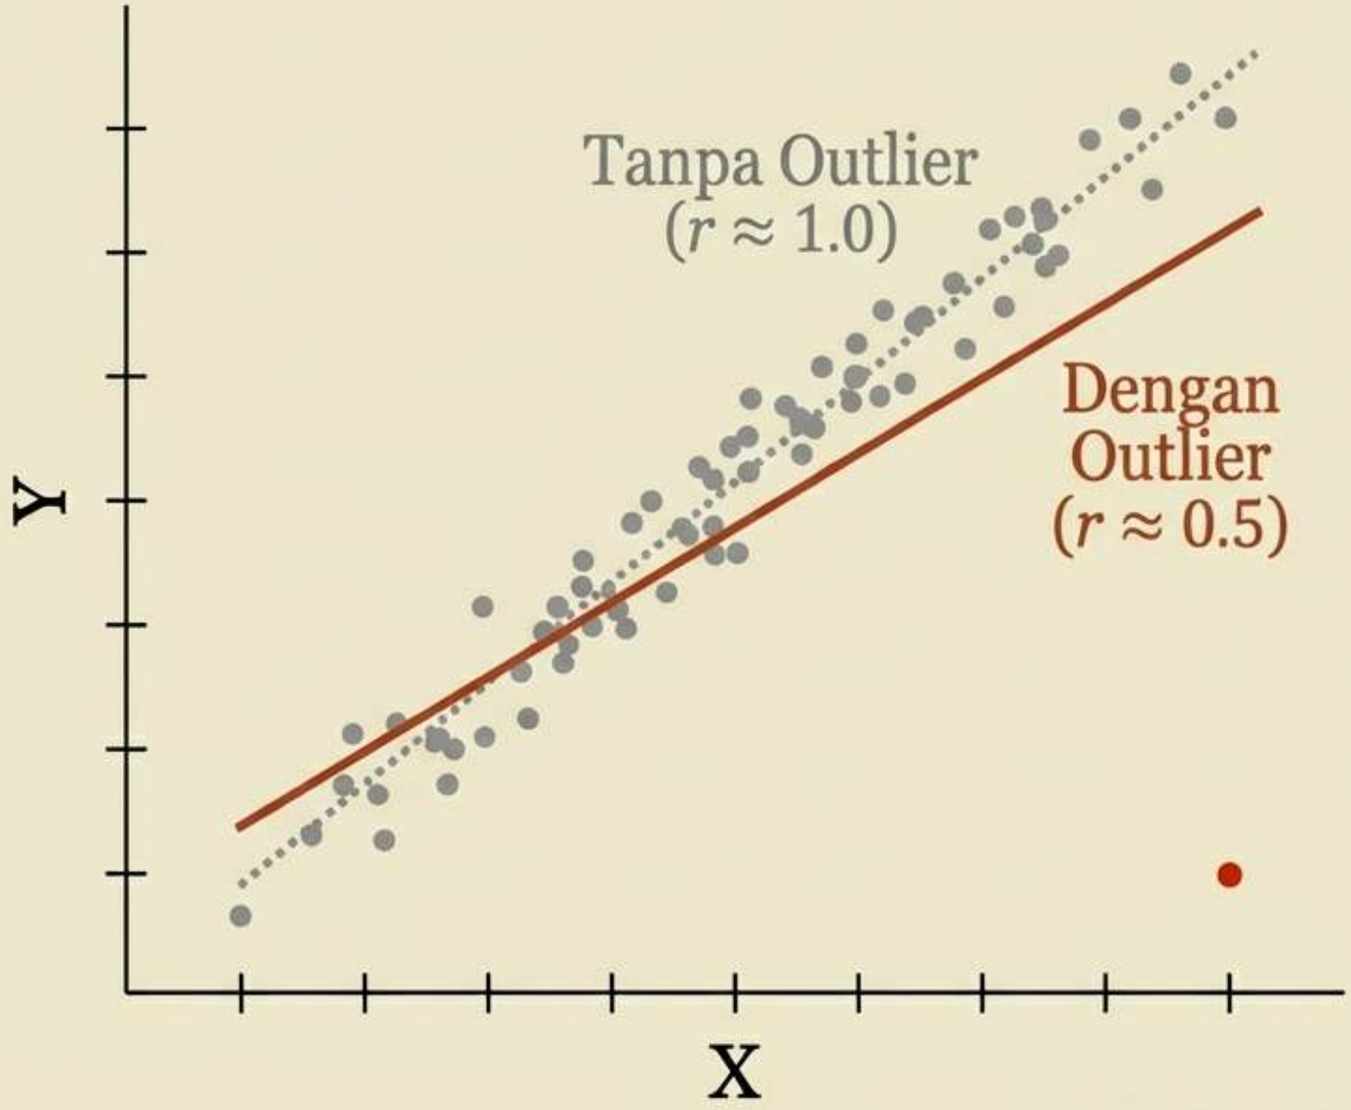

- **Kelemahan Kritis:** Pearson sangat sensitif terhadap pencilan (*outliers*). Satu data ekstrem dapat merusak akurasi koefisien secara drastis.
- **Asumsi Distribusi:** Inferensi standar mengasumsikan distribusi *Normal Bivariat*. Pada distribusi *Heavy-tailed* (ekor tebal), varians mungkin tidak stabil, menjadikan ρ menyesatkan.

Saran: Selalu inspeksi visual *scatterplot* sebelum menghitung, atau gunakan korelasi Rank (Spearman) jika terdapat outlier.

NotebookLM

Limitasi Linearitas: Anscombe's Quartet

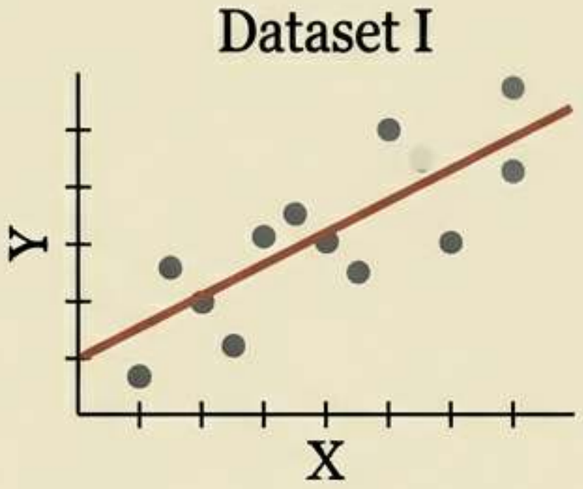

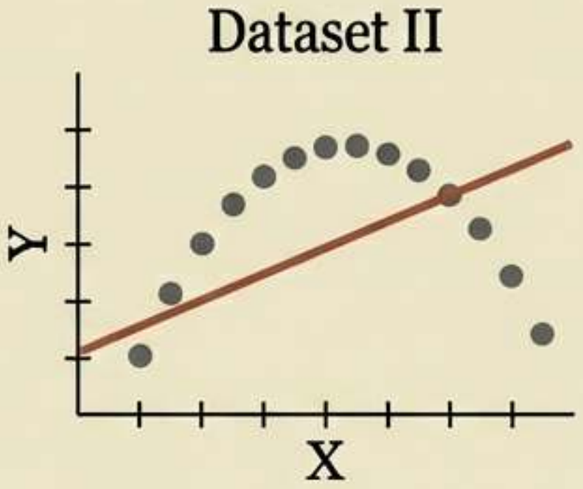

Statistik Identik untuk Keempat Dataset:

- Rata-rata X: 9.0
- Rata-rata Y: 7.50
- **Korelasi Pearson** (r): **0.816**
- Garis Regresi Linear: $y = 3 + 0.5x$

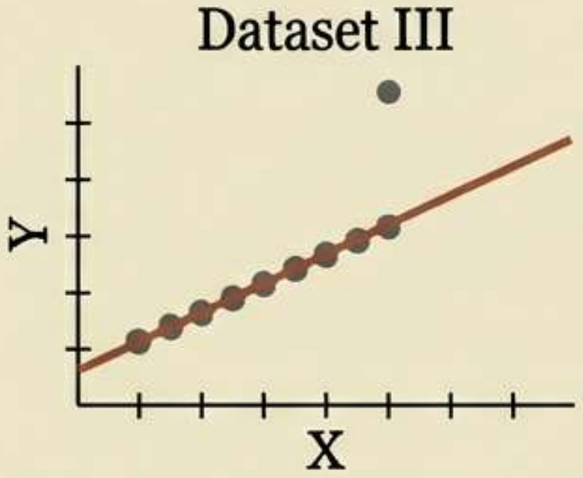

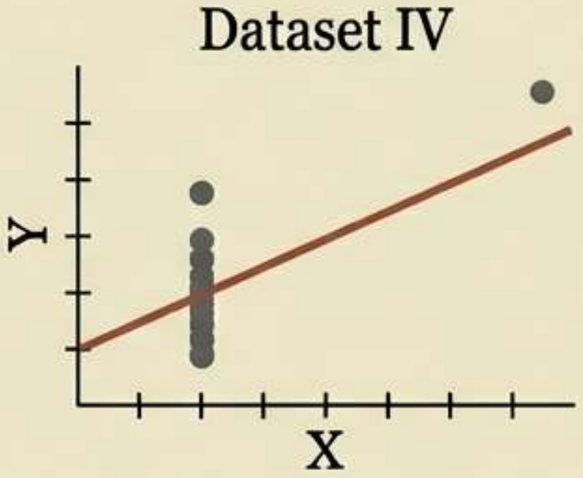

Pelajaran: 'Correlation is not Curve'. Angka statistik deskriptif yang sama dapat menyembunyikan struktur data yang sangat berbeda. Visualisasi adalah syarat mutlak.

NotebookLM

Varian Koefisien untuk Situasi Khusus

Adjusted Correlation (r_{adj})
- *Kapan*: Sampel kecil ($n < 50$).
- *Kenapa*: Korelasi sampel cenderung bias (sedikit meremehkan ρ). Penyesuaian ini mengoreksi bias tersebut.

Weighted Correlation
- *Kapan*: Observasi memiliki kualitas atau bobot kepentingan berbeda.
- *Mekanisme*: Memberikan bobot vektor w pada setiap pasangan (x_i, y_i) dalam perhitungan kovarians.

Reflective Correlation
- *Kapan*: Data tidak dipusatkan (*uncentered*).
- *Konsep*: Identik dengan *Cosine Similarity* pada data mentah. Mengukur kemiripan arah vektor tanpa mempedulikan rata-rata.

Scaled Correlation
- *Kapan*: Data deret waktu (*time series*).
- *Fungsi*: Memfilter komponen sinyal lambat untuk fokus pada korelasi jangka pendek (sinyal cepat).

NotebookLM

Aplikasi Lanjutan & Ekstensi

Partial Correlation

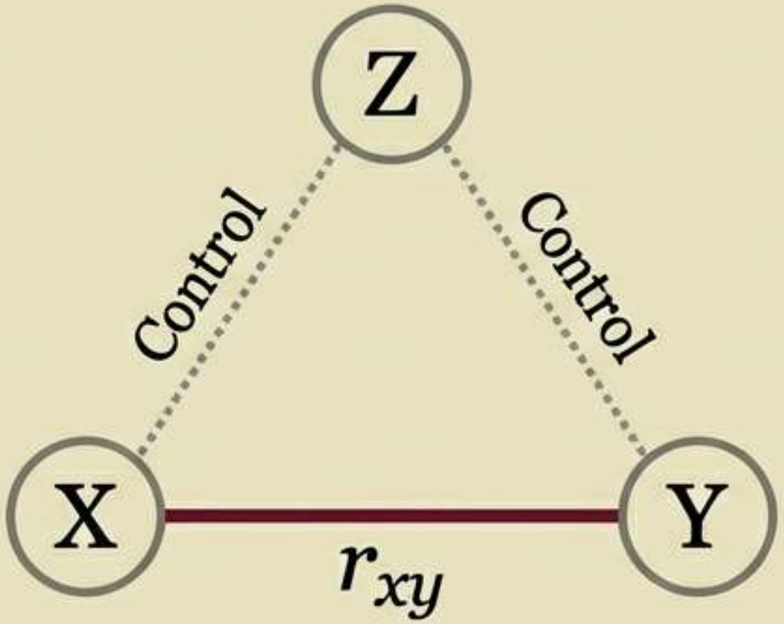

Mengukur hubungan murni antara X dan Y setelah menghilangkan efek variabel pengganggu Z.

Whitening & Decorrelation

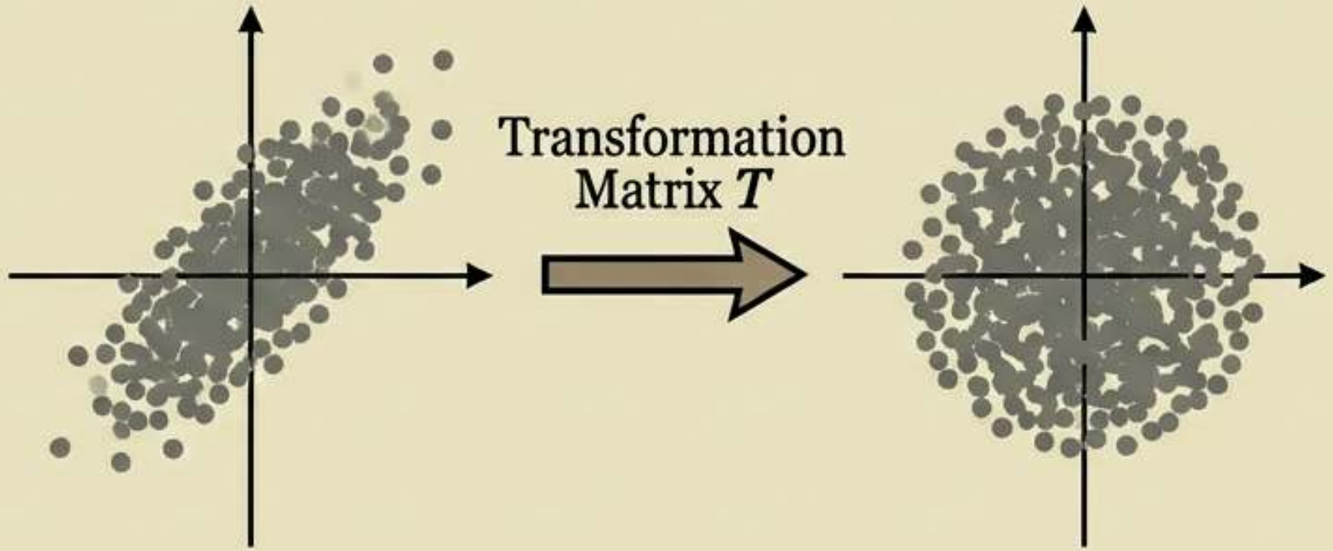

Transformasi data untuk menghilangkan korelasi antar *semua* variabel. Ini adalah basis dari *Principal Component Analysis* (PCA).

NotebookLM

Implementasi Praktis dan Ringkasan

Implementasi Kode

Python (Pandas)

```
df.corr(method='pearson')
```

Python (SciPy)

```
stat, p_value =
scipy.stats.pearsonr(x, y)
```

R Language

```
cor(x, y)
cor.test(x, y)
```

Ringkasan Eksekutif

1. **Alat Linear**: Pearson sangat kuat (*powerful*) namun spesifik untuk hubungan linear saja.
2. **Buta Struktur**: Ia tidak dapat mendeteksi hubungan non-linear (lengkungan) atau klaster kompleks.
3. **Sensitif**: Hati-hati terhadap outlier yang dapat membiaskan hasil secara ekstrem.
4. **Best Practice**: Gunakan sebagai langkah awal *Exploratory Data Analysis*, dan selalu validasi dengan scatterplot.

NotebookLM