

Achieving High Quality Portfolio Optimization with VQE

Phase 0: Theoretical Derivation

Team DreamyTA

January 6, 2026

Outline

- 1 QUBO to Ising Hamiltonian Mapping
- 2 VQE and CVaR
- 3 Weighted CVaR (WCVaR)
- 4 Weighting Schemes
- 5 CMA-ES Optimization

Formulasi Fungsi Objektif

Masalah optimisasi portfolio dirumuskan sebagai masalah QUBO:

$$C(x) = -\lambda \sum_{i=1}^N \mu_i x_i + (1 - \lambda) \sum_{i=1}^N \sum_{j=i+1}^N \sigma_{ij} x_i x_j + p \left(\sum_{i=1}^N x_i - \frac{N}{2} \right)^2 \quad (1)$$

Di mana:

- $x_i \in \{0, 1\}$: Variabel keputusan biner.
- N : Jumlah total aset.
- μ_i : Pengembalian yang diharapkan dari aset i .
- σ_{ij} : Kovarian antara aset i dan j .
- λ : Parameter penghindaran risiko ($0 \leq \lambda \leq 1$).
- p : Koefisien penalti untuk batasan kardinalitas ($\sum x_i = N/2$).

Ekspansi Batasan

Mengekspansi suku penalti kuadrat:

$$\begin{aligned}\left(\sum_{i=1}^N x_i - \frac{N}{2}\right)^2 &= \left(\sum_{i=1}^N x_i\right)^2 - N \sum_{i=1}^N x_i + \frac{N^2}{4} \\ &= \sum_{i=1}^N x_i + 2 \sum_{i < j} x_i x_j - N \sum_{i=1}^N x_i + \text{konst} \\ &= \sum_{i=1}^N (1 - N) x_i + 2 \sum_{i < j} x_i x_j + \text{konst}\end{aligned}$$

Mensubstitusi kembali ke dalam $C(x)$ menghasilkan koefisien yang dikelompokkan.

Menulis ulang $C(x)$ dengan koefisien linier (Q_i) dan kuadratik (Q_{ij}):

$$C(x) = \sum_{i=1}^N Q_i x_i + \sum_{i=1}^N \sum_{j=i+1}^N Q_{ij} x_i x_j + \text{konst} \quad (2)$$

Koefisien

- **Linier (Q_i):** $Q_i = -\lambda\mu_i + p(1 - N)$
- **Kuadratik (Q_{ij}):** $Q_{ij} = (1 - \lambda)\sigma_{ij} + 2p$

Transformasi ke Hamiltonian Ising

Pemetaan ke model Ising menggunakan $x_i = \frac{1-Z_i}{2}$, dengan $Z_i \in \{1, -1\}$ (nilai eigen Pauli-Z).

1. Suku Linier:

$$\sum_i Q_i x_i = \sum_i \frac{Q_i}{2} - \sum_i \frac{Q_i}{2} Z_i$$

2. Suku Kuadratik:

$$\sum_{i < j} Q_{ij} x_i x_j = \sum_{i < j} \frac{Q_{ij}}{4} (1 - Z_i - Z_j + Z_i Z_j)$$

Ekspresi Hamiltonian Akhir

Hamiltonian diberikan oleh $H = \sum_i h_i Z_i + \sum_{i < j} J_{ij} Z_i Z_j$.

Koefisien

$$h_i = \frac{\lambda \mu_i}{2} - \frac{1 - \lambda}{4} \sum_{j \neq i}^N \sigma_{ij} \quad (3)$$

$$J_{ij} = \frac{(1 - \lambda) \sigma_{ij} + 2p}{4} \quad (4)$$

Tujuan VQE: Meminimalkan $E(\theta) = \langle \psi(\theta) | \hat{H} | \psi(\theta) \rangle$.

CVaR Standar (Conditional Value-at-Risk): Alih-alih rata-rata, gunakan rata-rata dari energi ekor. Untuk energi yang diurutkan $E_{(1)} \leq \dots \leq E_{(K)}$:

$$CVaR_{\alpha}(E) = \frac{1}{\lceil \alpha K \rceil} \sum_{k=1}^{\lceil \alpha K \rceil} E_{(k)} \quad (5)$$

Ketika $\alpha = 1$, ini menghasilkan energi rata-rata standar.

Definisi

$$WCVaR_{\alpha}(E) = \sum_{k=1}^{\lceil \alpha K \rceil} w_k E_{(k)} \quad (6)$$

dengan batasan $\sum w_k = 1$.

Perbedaan dari CVaR Standar:

- **CVaR Standar:** Bobot seragam $w_k = \frac{1}{\lceil \alpha K \rceil}$.
- **WCVaR:** Bobot tidak seragam, biasanya meluruh secara eksponensial.

- **Lanskap yang Lebih Halus:** Tidak seperti optimisasi energi minimum ($\alpha \rightarrow 0$), WCVaR memberikan lanskap yang lebih halus dan dapat diturunkan.
- **Menghindari Dataran Tandus:** Tidak seperti ekspektasi penuh ($\alpha = 1$), ini berfokus pada keadaan energi rendah, mencegah derau energi tinggi menghapus gradien.
- **Panduan:** Bobot eksponensial mendorong pengoptimal secara agresif menuju keadaan dasar sejati ($E_{(1)}$).

Skema Pembobotan (Lampiran A)

- ❶ **Berbasis Energi:** $w_k = \exp[-\beta(E_{(k)} - E_0)]$ (Performa buruk).
- ❷ **Berbasis Peringkat:** $w_k = \exp(-\beta k)$ (Sederhana dan efektif).
- ❸ **Eksponensial Bertahap (Dipilih):**

$$w_k = \begin{cases} \exp(-\beta_1 k) & k < N_1 \\ \exp(-\beta_2(k - N_1)) \cdot w_{N_1-1} & N_1 \leq k < N_2 \\ \dots & \dots \end{cases}$$

Metode bertahap memungkinkan kontrol yang lebih rinci dan digunakan untuk hasil utama makalah.

Covariance Matrix Adaptation Evolution Strategy (CMA-ES)

- Algoritma optimisasi numerik stokastik tanpa turunan yang kuat.
- **Tipe:** Algoritma Evolusioner (domain kontinu).
- **Kasus Penggunaan:** Fungsi objektif non-konveks, tidak terkondisi dengan baik, multimodal, atau berisik.
- **Relevansi dengan VQE:** Digunakan untuk mengoptimalkan parameter θ dari sirkuit variasional ketika gradien sulit dihitung atau berisik (misalnya, pada perangkat keras NISQ).



Algoritma mempertahankan distribusi Gaussian $\mathcal{N}(m, \sigma^2 C)$ dan memperbaruinya secara iteratif:

- ❶ **Pengambilan Sampel:** Menghasilkan populasi solusi kandidat baru (keturunan) dari distribusi saat ini.
- ❷ **Seleksi:** Mengevaluasi kebugaran (energi) dan memilih kandidat terbaik.
- ❸ **Adaptasi:** Memperbarui parameter distribusi:
 - **Mean (m):** Bergerak menuju solusi yang lebih baik.
 - **Ukuran Langkah (σ):** Mengontrol eksplorasi vs. eksploitasi.
 - **Matriks Kovarian (C):** Mempelajari bentuk lanskap (korelasi antar variabel) untuk memandu pencarian.

Ilustrasi CMA-ES: Langkah 1

Inisialisasi



Pencarian dimulai dengan mean awal dan distribusi yang luas.



Ilustrasi CMA-ES: Langkah 2

Pengambilan Sampel & Seleksi



Kandidat diambil sampelnya; yang terbaik (biru) dipilih untuk memandu pembaruan.



Ilustrasi CMA-ES: Langkah 3

Adaptasi



Distribusi bergeser dan membentuk ulang (pembaruan kovarian) menuju lembah.



Ilustrasi CMA-ES: Langkah 4



Eksplorasi

Algoritma mengeksplorasi lanskap, memanjang sepanjang arah optimal.





Konvergensi Dimulai

Ukuran langkah menurun saat populasi berpusat pada minimum.



Penyetelan Halus

Lokalisasi presisi dari optimum.



Optimisasi Selesai

Distribusi konvergen ke minimum global.

